Introdução à acessibilidade urbana

um guia prático em R

Rafael H. M. Pereira, Daniel Herszenhut

2022-09-30T00:00:00+00:00

Table of contents

Apresentação

O objetivo deste livro é apresentar uma introdução sobre os conceitos e habilidades práticas necessárias para fazer estudos e avaliações de impacto sobre acessibilidade urbana. O livro começa dando uma visão geral sobre o conceito e indicadores de acessibilidade. Em seguida, ensina como analisar dados espaciais e de redes de transporte para se calcular estimativas de acessibilidade por diferentes modos de transporte e como visualizar esses resultados em mapas e gráficos. O livro também busca familiarizar o leitor com dados de redes de transporte público em formato GTFS e ensina como manipular e visualizar esse tipo de dado. Num dos seus principais capítulos, o livro ensina ainda como os dados e metodologia apresentados nos capítulos anteriores podem ser utilizados para avaliar o impacto de projetos de transporte sobre as condições de acesso a oportunidades da população. Por fim, o livro ensina como baixar, analisar e visualizar estimativas de acessibilidade já calculadas para cidades brasileiras e disponibilizadas pela equipe do Projeto Acesso a Oportunidades (AOP) do Ipea.

O conteúdo do livro foi pensado para as necessidades de trabalho de gestores públicos, além de analistas, alunos e pesquisadores de planejamento e transporte urbano. Por isso, o livro tem caráter prático. Todo material do livro é apresentado com exemplos reproduzíveis e dados abertos utilizando-se programação em R.

Organização do livro

Este livro está dividido em 5 seções:

1. Seção 1: A primeira seção apresenta o conceito de acessibilidade urbana, esclarece a diferença entre acessibilidade e mobilidade urbana, e apresenta os principais indicadores usados para medir a acessibilidade urbana.
2. Seção 2: A segunda seção ensina como calcular estimativas de acessibilidade urbana em R usando os pacotes `r5r` e `accessibility` a partir de dados públicos abertos.
3. Seção 3: A terceira seção apresenta o que é a especificação GTFS de dados de transporte público, e mostra como trabalhar e analisar dados de GTFS usando R.
4. Seção 4: A quarta seção mostra como o conhecimento dos capítulos anteriores pode ser utilizado para se avaliar o impacto de políticas urbanas sobre condições de acessibilidade urbana usando R.

5. Seção 5: Por fim, a quinta seção mostra como fazer download e analisar os dados do projeto Acesso a Oportunidades (AOP) para analisar a distribuição espacial e socioeconômica das condições de acesso a oportunidades nas cidades brasileiras.

Licença de uso

Como citar o livro

Caso você use o material deste livro, pedimos por gentileza que você cite o livro utilizando a seguinte referência:

- Pereira, Rafael H. M. & Herszenhut, Daniel. (2022) Introdução à acessibilidade urbana um guia prático em R. Instituto de Pesquisa Econômica Aplicada.

Agradecimentos

Este livro foi elaborado pelo Instituto de Pesquisa Econômica Aplicada (Ipea) no âmbito da parceria entre Ipea e a Secretaria de Mobilidade e Desenvolvimento Regional e Urbano (SMDRU) do Ministério do Desenvolvimento Regional (MDR).

> **i** Este livro foi escrito e publicado com o sistema de publicação Quarto. Todo o código utilizado em seu preparo e na sua publicação do pode ser encontrado neste repositório.

Part I

SEÇÃO 1: Introdução à acessibilidade urbana

Objetivo: O objetivo desta seção é (1) apresentar o conceito de acessibilidade urbana, esclarecendo a diferença entre acessibilidade e mobilidade; e (2) apresentar uma visão geral dos principais indicadores usados para medir acessibilidade.

Quantos postos de trabalho se consegue acessar em menos de uma hora usando transporte público? Quanto tempo se leva para chegar até o posto de saúde ou escola mais próxima da sua casa? As respostas a essas perguntas dependem diretamente das políticas de transporte e de desenvolvimento urbano das cidades. Essas políticas determinam em larga medida a acessibilidade urbana, isto é, a facilidade com a qual pessoas de diferentes grupos sociais e níveis de renda distintos conseguem acessar oportunidades de emprego, serviços de saúde e educação, atividades culturais e de lazer. Assim, essas políticas têm papel-chave para o funcionamento da economia, para a construção de cidades mais sustentáveis e inclusivas e para a redução da desigualdade de acesso a oportunidades.

1 O que é acessibilidade?

1.1 Definição de acessibilidade urbana

Acessibilidade é a facilidade com que as pessoas conseguem alcançar lugares e oportunidades – ou, inversamente, uma característica de lugares e oportunidades em termos de quão facilmente eles podem ser alcançados pela população (Geurs & van Wee, 2004; Neutens et al., 2010).

As condições de acessibilidade são influenciadas tanto pela co-distribuição espacial da população e de atividades econômicas e serviços públicos quanto pela configuração e desempenho das redes de transporte. Nesse sentido, a acessibilidade urbana tem papel fundamental na capacidade das pessoas de se deslocarem para acessar oportunidades, como empregos, escolas, etc.

As condições de acessibilidade urbana são moldadas por três componentes:

- **Infraestrutura**: A facilidade de acessar atividades depende da infra-estrutura e dos serviços de transporte existentes. Isso inclui, por exemplo, a capilaridade da rede de transporte público, a conectividade da rede viária, a existência de corredores de transporte de alta capacidade como trens, metrôs etc. Aqui, tanto a eficiência quanto a conectividade espacial e temporal da rede de transporte tem papel chaves.
- **Uso do solo**: A facilidade de acessar atividades também depende da co-distribuição espacial de pessoas, áreas residenciais e atividades como escolas, serviços de saúde, áreas de lazer, etc. Esse componente diz respeito à proximidade geográfica entre pessoas e oportunidades.
- **Pessoas**: A facilidade de acessar atividades também é afetada pelas características das pessoas. Fatores como deficiência físicas e cognitivas, idade, gênero, cor, e renda, por exemplo, podem influenciar de maneira importante a velocidade das pessoas se locomoverem, sua capacidade de utilizar determinados modos de transporte, e sua capacidade de circular pela cidade sem medo de algum tipo de violência ou descriminação.

1.2 Por que acessibilidade importa?

O conceito de acessibilidade é central em estudos de transporte por várias razões. Esse conceito articula de maneira mais explícita como políticas de transporte e políticas de desenvolvimento

e uso do solo urbano interagem de maneira a impactar as capacidades das pessoas de se deslocarem nas cidades. O acesso a postos trabalho, serviços de educação e saúde tem papel fundamental para a satisfação das necessidades individuais e sociais, e é uma condição necessária, embora não suficiente, para a expansão da liberdade de escolha das pessoas Lucas et al. (2016). Ademais, a ideia de acessibilidade traz à tona a dimensão espacial da injustiça e desigualdade no acesso a oportunidades, e ajuda a incorporar de maneira explícita a noção de espaço no desenho de políticas destinadas a enfrentar essas injustiças Pereira, Schwanen, and Banister (2017).

O nível de acesso a oportunidades numa cidade é um resultado conjunto da capacidade de as pessoas utilizarem tecnologias de transporte e da integração entre a distribuição geográfica de atividades vis-à-vis a conectividade espacial e temporal da rede de transporte Páez, Scott, and Morency (2012). Assim, a construção de cidades mais inclusivas e sustentáveis passa, em larga medida, por um planejamento integrado entre uso do solo e do sistema de transporte, o que tende a criar maior proximidade entre pessoas e atividades, aumentando a acessibilidade urbana e reduzindo a dependência de modos de transporte motorizados (Banister 2011).

1.3 Diferença entre micro e macro acessibilidade

Para fins de esclarecimento de conceitos, é importante distinguir entre o que nós chamamos de acessibilidade urbana e o uso mais corrente que é feito no português da palavra acessibilidade.

O termo *acessibilidade* é comumente utilizado para se referir a questões relacionadas à normas de design universal, construção e planejamento para inclusão de pessoas com diferentes graus e tipos de deficiência física. Isso é o que nós podemos chamar de microacessibilidade, pois trata na escala micro individual da capacidade de pessoas conseguirem acessar lugares, serviços, produtos etc.

A expressão *acessibilidade urbana*, por sua vez, pode ser entendida como macroacessibilidade, pois trata de uma maneira mais ampla sobre como a capacidade de acessar atividades considerando tanto as capacidades das pessoas utilizarem tecnologias de transporte quanto a distribuição espacial de atividades vis-à-vis a cobertura e conectividade da rede de transporte.

Notadamente, a microacessibilidade é um importante componente de uma noção mais ampla de acessibilidade urbana. Condições de microacessibilidade afetam diretamente a capacidade de pessoas embarcarem e utilizarem diferentes modos de transporte, de se locomoverem com segurança sobre calçadas e atravessar ruas etc.. Ainda, ambas micro e macroacessibilidade têm papel fundamental em moldar as condições de mobilidade urbana da população.

1.4 Diferença entre acessibilidade e mobilidade urbana

O conceito de acessibilidade é diferente, mas complementar ao de mobilidade urbana. Estudos sobre mobilidade urbana costumam olhar para os padrões de viagens que as pessoas efetivamente fazem no seu dia a dia – por exemplo, quantas viagens foram feitas, que modo de transporte as pessoas usam, qual a distância média das viagens, qual o tempo de deslocamento casa-trabalho etc. Informações de mobilidade são tipicamente captadas por meio de pesquisas de origem-destino, ou dados de GPS de telefones celulares, cartões de bilhetagem eletrônica etc. Dados sobre mobilidade urbana trazem informações importantes sobre as condições diárias de transporte e padrões de viagens, que captam aspectos importantes do desempenho econômico e ambiental das cidades e o bem-estar da população.

Tradicionalmente, o planejamento urbano e de transportes tem como foco melhorar a mobilidade urbana Levinson and King (2020). Esse foco na mobilidade tem motivado políticas que priorizam a circulação de automóveis, e visam aumentar a velocidade e a fluidez de trânsito para reduzir congestionamentos (Banister 2011). No entanto, a mobilidade não é um fim em si mesma. Via de regra, as pessoas se deslocam como um meio para acessar as atividades no destino da viagem.

Nesse sentido, tem-se observado um crescente consenso entre pesquisadores e agências de transporte que o objetivo de uma política de transporte é melhorar o acesso da população Bertolini, le Clercq, and Kapoen (2005). Se o que as pessoas querem é acessar atividades, então é possível pensar em formas de planejamento que facilitem as pessoas alcançarem tais atividades sem necessariamente promover o aumento da motorização e da velocidade no trânsito. Isso por ser alcançado, por exemplo, por políticas que promovem maior mix de uso do solo e maior integração entre planejamento de transporte e uso do solo e maior proximidade entre pessoas e atividades.

Quando o foco da política sai da mobilidade e passa a ser melhorar a acessibilidade urbana, abre-se um leque maior de possíveis instrumentos e ações de políticas públicas para promover um desenvolvimento urbano mais integrado e calcado na promoção da sustentabilidade e inclusão social Banister (2011).

2 Indicadores de acessibilidade

Existem diversos indicadores para se medir acessibilidade. Esses indicadores podem ser divididos em dois grandes grupos: indicadores baseados em lugar e indicadores baeados em pessoas (Dijst, de Jong, and van Eck 2002).

2.1 Medidas baseadas em lugares

Medidas baseadas em lugar medem a acessibilidade enquanto uma característica de um determinado local. Por simplificação, esses indicadores assumem que todas as pessoas que se encontram em um mesmo local têm as mesmas condições de acesso às atividades distribuídas pela cidade. Esses indicadores são sensíveis a fatores relacionados à distribuição espacial de atividades e à configuração e desempenho da rede de transporte, mas não levam em consideração as características individuais das pessoas.

Os indicadores desse tipo são os mais amplamente utilizados por agências de transporte e pesquisadores (**boisjoly2017get?**). Isso porque esses indicadores exigem menor quantidade de dados e são consideravelmente mais fáceis de serem calculados. Por este motivo, todo o material deste curso irá focar nesses indicadores de acessibilidade baseados em lugares.

Nós apresentamos abaixo uma rápida descrição de alguns desses indicadores. Note que, em geral, esses indicadores são medidos com base num custo de transporte calculado em termos de tempo de viagem. No entanto, o termo "custo" é utilizado aqui de maneira mais ampla, e pode se referir a outros tipos de custo como a distância de viagem ou seu custo monetário.

2.1.1 Mínimo custo de viagem

O Indicador de mínimo custo de viagem aponta qual o menor custo (por exemplo, em termos de tempo ou distância) de viagem até a oportunidade mais próxima. Ele permite captar, por exemplo, qual o tempo de viagem até o posto de saúde mais próximo. Esse é um dos indicadores mais simples de acessibilidade.

$$A_i = min(c_{i1}, c_{i2}, ..., c_{ij}, ..., c_{i(n-1)}, c_{in}) \iff O_j \geq 1$$

em que A_i é a acessibilidade na origem i, c_{ij} é o custo de deslocamento entre a origem i e o destino j, n é o número total de destinos na área de estudo e O_j é o número de oportunidades no destino j.

Vantagens e desvantagens: Este indicador tem as vantagens de ser fácil de se calcular com pouca exigência de dados, além de ser fácil de comunicar. Duas desvantagens, no entanto, é que ele não capta a quantidade de oportunidades acessíveis e nem aspectos de competição na demanda pela oportunidade. Por exemplo, uma pessoa pode morar muito perto de um hospital, mas essa proximidade pode não garantir um bom acesso aos serviços de saúde se esse for o único hospital da região que fica sobrecarregado com demanda de pacientes.

2.1.2 Medida cumulativa de oportunidades

O indicador de oportunidades cumulativas mede a quantidade de oportunidades que podem ser alcançadas dentro de um tempo máximo de viagem. Por exemplo, este indicador pode ser utilizado para medir a quantidade de empregos acessíveis por transporte público em até 60 minutos, ou a quantidade de escolas acessíveis em até 30 minutos de viagem a pé.

$$A_i = \sum_{j=1}^{n} O_j \times f(c_{ij})$$

$$f(c_{ij}) = \begin{cases} 1 & \text{se } c_{ij} \leq C \\ 0 & \text{caso contrário} \end{cases}$$

em que A_i é a acessibilidade na origem i, O_j é o número de oportunidades no destino j, n é o número total de destinos na área de estudo, $f(c_{ij})$ é um função binária que assume os valores 0 ou 1, a depender do custo de deslocamento c_{ij} entre a origem i e o destino j, e C é o limite de custo de deslocamento estabelecido.

Vantagens Vs desvantagens: A medida cumulativa de oportunidades também também é fácil de se calcular com pouca exigência de dados, além de ser fácil de comunicar. Isso contribui para tornar este indicador um dos mais utilizados por agências de transporte e de financiamento para analisar acessibilidade (**boisjoly2017get?**). Entre as suas desvantagens, no entanto, cabe destacar que este indicador não considera a influência da competição sobre oportunidades. Este indicador também exige a escolha de um único ponto de corte como tempo máximo de viagem. Além disso, esta medida assume todas as oportunidades são igualmente desejáveis pelas pessoas, esteja ela a uma distância de 10 ou 40 minutos de viagem, desde que esses tempos de viagem estejam dentro do limite pré-estabelecido.

2.1.3 Medidas gravitacionais

Indicadores gravitacionais de acessibilidade também medem a quantidade de oportunidades acessíveis a partir de uma determinado local, mas a contagem de cada oportunidade é gradualmente descontada à medida que o custo da viagem aumenta. Assim, oportunidades mais próximas têm uma importância maior, e o peso de cada oportunidade diminui quanto mais distante ela estiver.

O ritmo de decaimento desse peso em função do custo da viagem é conhecido como função de impedância. Essa função pode ser definida seguindo diversas diferentes fórmulas funcionais. Por exemplo, é possível considerar um decaimento linear. Neste caso, o peso da oportunidade diminui de maneira contínua ao longo do espaço até certo ponto a partir da onde o peso passa a ser zero. Outra opção é considerar uma função negativa exponencial, onde o peso cai muito rapidamente em distâncias mais próximas mas passa a ter uma queda mais suave como pesos igualmente baixos para oportunidades muito distantes.

$$A_i = \sum_{j=1}^{n} O_j \times f(c_{ij})$$

$$f_{lin}(c_{ij}) = \begin{cases} 1 - c_{ij}/C & \text{se } c_{ij} \leq C \\ 0 & \text{caso contrário} \end{cases}$$

$$f_{exp}(c_{ij}) = e^{-\beta c_{ij}}$$

em que A_i é a acessibilidade na origem i, O_j é o número de oportunidades no destino j, n é o número total de destinos na área de estudo, $f(c_{ij})$ é uma função de decaimento cujo resultado varia com o custo de deslocamento c_{ij} entre a origem i e o destino j, $f_{lin}(c_{ij})$ é a função de decaimento linear, C é o limite de custo de deslocamento estabelecido, $f_{exp}(c_{ij})$ é a função de decaimento exponencial negativa e β é um parâmetro que dita a velocidade de decaimento.

Vantagens Vs desvantagens: A principal vantagem de indicadores gravitacionais é que o desconto do peso das oportunidades pela sua distância reflete de alguma maneira o comportamento de como as pessoas costumam se comportar. Serviços e atividades que gostaríamos de acessar costumam ser mais atrativas quanto mais próximas elas estiverem, tudo mais constante. Este indicador tem ao menos duas desvantagens. A primeira delas é que os valores de acessibilidade estimados são de difícil interpretação pela forma como a contagem de oportunidades é descontada pela distância. Além disso, para que o indicador seja mais representativo do comportamento de viagem das pessoas, a forma funcional e o ritmo de decaimento da função de impedância precisam ser calibradas. Por isso, este indicador também requer a disponibilidade de dados de padrões de viagens disponíveis, por exemplo, a partir de pesquisas de origem destino.

2.1.4 Indicadores de acessibilidade com competição: *floating catchment area*

Em muitos casos, o acesso a oportunidades é afetado não apenas por questões de proximidade e custos de transporte, mas também pela possível competição de muitas pessoas que querem acessar a mesma oportunidade ao mesmo tempo. Isso é muito comum, por exemplo, em casos de acesso a serviços de saúde, escolas e empregos. Uma vaga de emprego só pode ser ocupada por uma pessoa de cada vez, o mesmo vale por exemplo para um leito de UTI ou vaga em uma escola.

Existe uma gama de indicadores de acessibilidade que buscam levar em consideração essa possível competição pelas oportunidades acessíveis. Vários desses indicadores são do tipo *floating catchment area* (áreas de influência flutuantes, em tradução livre). A título de exemplo, esses indicadores tentam levar em consideração como uma mesma pessoa pode potencialmente acessar vários leitos de UTI e, simultaneamente, como cada leito de UTI pode ser acessado por diversas pessoas. Assim, o acesso de uma pessoa ao serviço de leito de UTI é influenciado não apenas por questões de custos de transporte mas também pela disponibilidade de leitos de UTI por pessoas que potencialmente poderiam acessar os mesmos leitos.

Dentro dessa família de indicadores tipo *floating catchment area* (FCA). O indicador mais comumente utilizado é o *2-Step Floating Catchment Area* (2SFCA), proposto originalmente por Luo and Wang (2003). Uma limitação do 2SFCA é qu ele ele contabiliza que uma mesma pessoa pode potencialmente demandar várias oportunidades ao mesmo tempo, e que um mesmo serviço pode ser potencialmente utilizado por várias pessoas ao mesmo tempo. Isso é conhecido como problema de inflação de demanda e de oferta, respectivamente, e pode gerar estimativas enviesadas de acessibilidade (Paez, Higgins, and Vivona 2019). Para lidar com esse problema, Paez et al (2019) propuseram o indicador *Balanced Floating Catchment Area* ("BFCA"), uma das medidas mais novas na família de indicadores tipo *floating catchment area*.

Vantagens Vs desvantagens: Diferentes indicadores desse tipo vão ter pequenas variações em duas vantagens e desvantagens. No entanto, de uma maneira geral, a principal vantagem de indicadores tipo *floating catchment area* é a sua capacidade de incorporar aspectos de competição em medidas de acessibilidade. Uma das desvantagens destes tipos de indicadores é a difícil interpretação e comunicação dos seus resultados.

2.2 Medidas baseadas em pessoas

Indicadores de acessibilidade baseadoas em pessoas são sensíveis não apenas à distribuição espacial de atividades e a configuração e desempenho da rede de transporte. Esses indicadores mas também levam em consideração como características pessoais (como sexo, idade, deficiência física etc) e até questões como atividades e compromissos pessoais podem afetar a facidade de uma pessoa acessar determinadas atividades. Esse grupo de medidas inclui, por exemplo, indicadores de acessibilidade baseados em utilidade Miller (2018), indicadores baseados em atividades (Dong et al. 2006) ou medidas de espaço-tempo Neutens et al. (2012).

Embora esses tipos de indicadores sejam mais sofisticados, eles costumam demandar grandes quantidades de dados, incluindo registros de diários de viagem, pesquisas domiciliares tipo origem-destino etc. Por isso, o cálculo desses indicadores é computacionalmente mais intensivo e complexo, o que faz com que esses indicadores sejam menos utilizados Miller (2018).

Part II

SEÇÃO 2: Calculando acessibilidade

Objetivo: O objetivo desta seção é mostrar como calcular estimativas de acessibilidade urbana em R usando os pacotes `r5r` e `accessibility`.

O cálculo dos níveis de acessibilidade em um determinado local compreende duas etapas principais: primeiro, nós precisamos calcular uma matriz de custo, geralmente o tempo de viagem, entre as origens e os destinos de uma determinada cidade ou região considerando um modo de transporte; feito isso, calculamos a acessibilidade em cada ponto de origem considerando os custos de transporte entre cada origem e o número de oportunidades em cada destino. Nesta seção nós aprenderemos mais sobre essas duas etapas usando R, quais dados são necessários para executá-las e quais as vantagens e desvantagens dos diferentes métodos que podem ser usados para isso.

3 Calculando acessibilidade urbana em R

3.1 Cálculo da matriz de tempo de viagem

Como comentado anteriormente, a primeira etapa necessária para calcular os níveis de acessibilidade de uma área urbana é calcular a matriz de custo de viagem entre as diversas origens e destinos que a compõem. Na literatura científica e na prática do planejamento de sistemas de transporte público, esse custo é mais frequentemente representado pelo tempo de viagem que separa dois pontos (El-Geneidy et al. 2016; Venter 2016), embora trabalhos recentes tenham considerado também outros fatores, como o dinheiro necessário para realizar uma viagem e o nível de conforto da viagem entre um ponto e outro (Arbex and Cunha 2020; Herszenhut et al. 2022). Pela prevalência deste tipo de matriz na literatura e na prática, porém, iremos nos focar em matrizes de tempo de viagem.

Atualmente, a forma mais fácil e rápida de gerar uma matriz de tempo de viagem em R é utilizando o pacote r5r (Pereira et al. 2021), desenvolvido pela equipe do Projeto Acesso a Oportunidades, do Ipea. O pacote utiliza, por trás dos panos, o *software* de roteamento multimodal de transporte público R5, desenvolvido pela Conveyal[1].

3.1.1 Instalação do r5r

A instalação do `r5r` funciona como a instalação de qualquer pacote no R.

```
install.packages("r5r")
```

Além do R, o pacote `r5r` requer também a instalação do Java 11[2]. Se você não sabe qual versão do Java você tem instalada em seu computador, você pode checar essa informação rodando este código no console do R.

```
cat(processx::run("java", args = "--version")$stdout)
```

[1] Disponível em https://github.com/ipeaGIT/gtfstools.

[2] Mais detalhes sobre o uso e a sintaxe do `data.table` podem ser lidos em https://rdatatable.gitlab.io/data.table/index.html.

```
openjdk 11.0.16 2022-07-19 LTS
OpenJDK Runtime Environment Zulu11.58+15-CA (build 11.0.16+8-LTS)
OpenJDK 64-Bit Server VM Zulu11.58+15-CA (build 11.0.16+8-LTS, mixed mode)
```

3.1.2 Dados necessários

O uso do pacote `r5r` requer os seguintes dados:

- **Rede viária** (obrigatório): um arquivo com a rede viária e de infraestrutura de pedestres do *OpenStreetMap*, em formato `.pbf`;
- **Rede de transporte público** (opcional): um arquivo GTFS descrevendo a rede de transporte público da área de estudo;
- **Topografia** (opcional): um arquivo de dados em *raster* com o modelo digital de elevação em formato `.tif`, caso deseje-se levar em consideração os efeitos da topografia do local sobre os tempos de caminhada.

Aqui estão alguns lugares de onde você pode baixar estes dados:

- OpenStreetMap
  - osmextract, pacote de R
  - geofabrik, website
  - hot export tool, website
  - BBBike.org, website
- GTFS
  - tidytransit, pacote de R
  - transitland, website
  - No capítulo X desde livro (tabela xx) nós indicamos também onde baixar os dados de GTFS de algumas cidades brasileiras que compartilham seus dados publicamente.
- Topografia
  - elevatr, pacote de R
  - Nasa's SRTMGL1, website

Os arquivos destes dados devem ser salvos em uma mesma pasta que, preferencialmente, não contenha nenhum outro arquivo. Como se verá adiante, o `r5r` combina todos os dados salvos nesta pasta para criar uma rede de transporte multimodal que será utilizada para simulações de roteamento e cálculo das matrizes de viagem. Note que é possível ter mais de um arquivo GTFS na mesma pasta, nesse caso o `r5r` irá considerar as redes de transporte públicos de todos *feeds*. No entanto, a pasta deve conter um único arquivo de rede viária `.pbf`. Assumindo que os scripts de R estarão em uma pasta chamada R, a organização dos arquivos deverá seguir o esquema abaixo:

```
/tmp/RtmpKJGCVd/projeto_acessibilidade
+-- R
|   +-- script1.R
|   \-- script2.R
\-- r5
    +-- rede_transporte_publico.zip
    +-- rede_viaria.osm.pbf
    \-- topografia.tif
```

Para ilustrar as funcionalidades do `r5r`, nós vamos usar uma pequena amostra de dados para a cidade de Porto Alegre (Brasil). Esses dados estão disponíveis dentro do próprio pacote `r5r` na pasta `system.file("extdata/poa", package = "r5r")`:

```
/home/runner/work/intro_access_book/intro_access_book/renv/library/R-4.2/x86_64-pc-linux-gnu/
+-- poa.zip
+-- poa_elevation.tif
+-- poa_hexgrid.csv
+-- poa_osm.pbf
\-- poa_points_of_interest.csv
```

Esta pasta possui quatro arquivos que vamos usar agora:

- A rede viária do OpenStreetMap: `poa_osm.pbf`
- Dois feeds de GTFS das redes de ônibus e de trens: `poa_eptc.zip` e `poa_trensurb.zip`
- O dado de topografia: `poa_elevation.tif`
- Um arquivo `poa_hexgrid.csv` com coordenadas geográficas dos centróides de uma grade hexagonal regular cobrindo toda a área da amostra e com informações sobre o tamanho da população residente e o número de oportunidades (empregos, escolas e hospitais) em cada hexágono. Esses pontos serão utilizados como os pontos de origem e destino no cálculo da matriz de tempo de viagem.

3.1.3 Calculando a matriz de tempo de viagens

Antes de calcular a matriz de tempo de viagem, precisamos aumentar a memória disponível para o Java. Isto é necessário porque, por padrão, o R aloca apenas 512MB de memória para processos Java, o que não é suficiente para grandes consultas usando `r5r`. Para aumentar a memória disponível para 2GB, por exemplo, precisamos definir um valor para o parâmetro `java.parameters` no início do script antes de carregar as bibliotecas do R:

```
options(java.parameters = "-Xmx2G")
```

Pronto, agora vamos carregar as bibliotecas que vamos utilizar neste capítulo.

```
library(r5r)
library(accessibility)
library(sf)
library(data.table)
library(ggplot2)
library(aopdata)
```

Feito isso, o cálculo de uma matriz de tempo de viagens da sua área de estudo pode ser feito em dois passos. O primeiro passo é gerar a rede de transporte multimodal que será utilizada no roteamento. Para isso, nós utilizamos a função `setup_r5()`. Esta função baixa o *software* de roteamento R5 e o utiliza para criar a rede. A função `setup_r5()` recebe como *input* o caminho da pasta onde você armazenou seus dados. Além da função salvar na pasta alguns arquivos necessários para o roteamento, ela também retorna uma conexão com o R5, que neste exemplo nós chamamos de `r5r_core`, e que será utilizada no cálculo da matriz de tempo de viagem.

```
path <- system.file("extdata/poa", package = "r5r")

r5r_core <- setup_r5(path, use_elevation = TRUE, verbose = FALSE)

fs::dir_tree(path)
```

```
/home/runner/work/_temp/renv/cache/v5/R-4.2/x86_64-pc-linux-gnu/r5r/0.7.1/61db001154cd833466a
+-- network.dat
+-- poa.zip
+-- poa_elevation.tif
+-- poa_hexgrid.csv
+-- poa_osm.pbf
+-- poa_osm.pbf.mapdb
+-- poa_osm.pbf.mapdb.p
\-- poa_points_of_interest.csv
```

O passo final é usar a função para o cálculo da matriz de tempo de viagem, apropriadamente chamada de `travel_time_matrix()`. Como *inputs* básicos, a função recebe a conexão com o R5 criada acima, pontos de origem e destino em formato de `data.frame` com as colunas `id`, `lon` e `lat`, o modo de transporte a ser utilizado, o horário de partida, o tempo máximo de caminhada permitido da origem até o embarque no transporte público e do desembarque até o destino, e o tempo máximo de viagem a ser considerado.

```
points <- fread(file.path(path, "poa_hexgrid.csv"))
```

```r
ttm <- travel_time_matrix(
  r5r_core,
  origins = points,
  destinations = points,
  mode = c("WALK", "TRANSIT"),
  departure_datetime = as.POSIXct(
    "13-05-2019 14:00:00",
    format = "%d-%m-%Y %H:%M:%S"
  ),
  max_walk_dist = 800,
  max_trip_duration = 120,
  verbose = FALSE,
  progress = FALSE
)

ttm
```

```
                fromId            toId travel_time
     1: 89a901291abffff 89a901291abffff           1
     2: 89a901291abffff 89a901295b7ffff          41
     3: 89a901291abffff 89a9012809bffff          43
     4: 89a901291abffff 89a901285cfffff          35
     5: 89a901291abffff 89a90e934d7ffff          71
    ---
1169147: 89a90166da7ffff 89a90129133ffff          58
1169148: 89a90166da7ffff 89a9012ac43ffff          93
1169149: 89a90166da7ffff 89a90129a47ffff          19
1169150: 89a90166da7ffff 89a90128883ffff          65
1169151: 89a90166da7ffff 89a90166da7ffff           0
```

Diversos outros *inputs* podem ser passados para o cálculo da matriz, como a velocidade de caminhada e o número máximo de pernas de transporte público permitido, entre outros. Para mais informações sobre cada um dos parâmetros, por favor consulte a documentação da função disponível no pacote ou no site do `r5r` aqui.

Na prática, o que a função `travel_time_matrix()` faz é encontrar qual a rota de viagem mais rápida partindo de cada ponto de origem para todos os possíveis pontos de destino considerando o modo de viagem, horário de partida e demais parâmetros passados pelo usuário. Para isso, o `r5r` considera tempos de viagem de porta-a-porta. No caso de uma viagem por transporte público, por exemplo, o tempo total de viagem inclui a) o tempo de caminhada até a parada de transporte público; b) o tempo de espera pelo veículo na parada; c) o tempo de deslocamento dentro do veículo; e d) o tempo de viagem a pé da parada de desembarque até o destino. Em

casos em que mais de uma rota de transporte público é utilizada, o `r5r` também contabiliza o tempo gasto nas conexões, considerando a caminhada entre paradas e o tempo de espera pelo próximo veículo.

> **i** A função `travel_time_matrix()` utiliza uma extensão do algoritmo de roteamento RAPTOR (Conway, Byrd, and van der Linden 2017), o que torna o R5 extremamente rápido. A depender da quantidade de pares de origem-destino, o `r5r` pode ser entre 6 e 200 vezes mais rápido do que *softwares* alternativos para calcular uma matriz de tempo de viagem (Higgins et al. 2022).

3.2 Cálculo de acessibilidade

Após calculada a matriz de tempo de viagem entre as origens e os destinos da área de estudo, nós precisamos utilizá-la para calcular os níveis de acessibilidade do local. Para isso, nós utilizaremos o pacote `accessibility`, também desenvolvido pela equipe do Projeto Acesso a Oportunidades, que contém diversas funções para vários indicadores de acessibilidade.

Como *input* básico, todas as funções requerem uma matriz de custo pré-calculada (no nosso caso, a matriz de tempo de viagem calculada na seção anterior) e dados de uso do solo, como o número de determinados tipos de oportunidades em cada ponto da área de estudo, por exemplo.

Medida cumulativa de acesso a oportunidades

O exemplo abaixo mostra uma simples aplicação da função `cumulative_cutoff()`, utilizada para calcular o número de oportunidades que pode ser alcançado em um determinado limite de custo de viagem. No exemplo abaixo, nós calculamos o número de postos de trabalho que podem ser alcançados em até 30 minutos de viagem a partir de cada origem presente em nossa matriz de tempo de viagem.

```
setnames(ttm, c("fromId", "toId"), c("from_id", "to_id"))

cumulative_access <- cumulative_cutoff(
  ttm,
  points,
  opportunity = "schools",
  travel_cost = "travel_time",
  cutoff = 30
)

cumulative_access
```

```
                  id schools
   1: 89a901291abffff      19
   2: 89a9012a3cfffff       0
   3: 89a901295b7ffff      15
   4: 89a901284a3ffff       0
   5: 89a9012809bffff      20
  ---
1223: 89a90129133ffff       4
1224: 89a9012ac43ffff       9
1225: 89a90129a47ffff      12
1226: 89a90128883ffff      31
1227: 89a90166da7ffff      15
```

Mínimo custo de viagem

A função `cost_to_closest()`, por sua vez, calcula o mínimo custo de viagem necessário para alcançar um determinado número de oportunidades. O código abaixo, por exemplo, calcula o tempo de viagem mínimo para alcançar o hospital mais próximo a partir de cada origem.

```
min_cost <- cost_to_closest(
  ttm,
  points,
  opportunity = "schools",
  travel_cost = "travel_time"
)
```

```
Warning in `[.data.table`(filled_access_df, is.na(get(access_col)),
`:=`(eval(access_col, : inf (type 'double') at RHS position 1 truncated
(precision lost) when assigning to type 'integer' (column 2 named 'min_cost')
```

```
min_cost
```

```
                  id travel_time
   1: 89a9012124fffff           0
   2: 89a9012126bffff          16
   3: 89a9012127bffff          11
   4: 89a90128003ffff           7
   5: 89a90128007ffff          20
  ---
1223: 89a90e934cbffff          13
1224: 89a90e934cfffff           9
```

```
1225: 89a90e934d3ffff           7
1226: 89a90e934d7ffff           0
1227: 89a90e934dbffff          23
```

Medidas gravitacionais de acessibilidade

A função `gravity()` calcula medidas gravitacionais de acessibilidade - ou seja, aquelas nas quais o peso de cada oportunidade diminui gradualmente com o aumento do custo de viagem. Existem, no entanto, uma gama de diferentes tipos de funções de decaimento que podem ser utilizadas, como funções de decaimento exponenciais negativas, de potências inversas, entre outras. Por isso, esta função recebe um *input* adicional: a função de decaimento a ser utilizada no cálculo. O exemplo abaixo apresenta o cálculo de acessibilidade a estabelecimentos de educação usando uma medida gravitacional exponencial negativa com parâmetro de decaimento igual a `0.2`.

```
negative_exp_access <- gravity(
  ttm,
  points,
  opportunity = "schools",
  travel_cost = "travel_time",
  decay_function = decay_exponential(0.2)
)

negative_exp_access
```

```
                 id    schools
   1: 89a901291abffff 0.35892873
   2: 89a9012a3cfffff 0.00000000
   3: 89a901295b7ffff 0.52061269
   4: 89a901284a3ffff 0.00000000
   5: 89a9012809bffff 0.44769080
  ---
1223: 89a90129133ffff 0.02885676
1224: 89a9012ac43ffff 0.09138463
1225: 89a90129a47ffff 0.35857154
1226: 89a90128883ffff 1.86366449
1227: 89a90166da7ffff 0.40513107
```

Indicadores de acessibilidade com competição

Por fim, a função `floating_catchment_area()` calcula níveis de acessibilidade levando em consideração a competição por oportunidades usando diferentes indicadores do tipo *floating*

catchment area. Como diversos métodos de FCA podem ser utilizados, a função requer que o método desejado seja explicitamente assinalado. E, assim como a função de acessibilidade gravitacional, a função de decaimento utilizada também deve ser definida pelo usuário. O código a seguir mostra um exemplo de cálculo de acessibilidade a oportunidades de emprego usando o método BFCA (Paez, Higgins, and Vivona 2019), levando em consideração os efeitos de competição entre a população como um todo e uma função de decaimento exponencial com parâmetro de decaimento igual a 2.

```
bfca_access <- floating_catchment_area(
  ttm,
  points,
  opportunity = "schools",
  travel_cost = "travel_time",
  demand = "population",
  method = "bfca",
  decay_function = decay_exponential(0.05)
)

bfca_access
```

```
                 id      schools
   1: 89a901291abffff 0.0002574442
   2: 89a9012a3cfffff 0.0000000000
   3: 89a901295b7ffff 0.0002091911
   4: 89a901284a3ffff 0.0000000000
   5: 89a9012809bffff 0.0002276971
  ---
1223: 89a90129133ffff 0.0001352617
1224: 89a9012ac43ffff 0.0001416331
1225: 89a90129a47ffff 0.0001777023
1226: 89a90128883ffff 0.0002372291
1227: 89a90166da7ffff 0.0001957669
```

As funções apresentadas nesta seção podem receber também outros *inputs* não explicitamente mencionados aqui. Para mais informações sobre cada um dos parâmetros, por favor consulte a documentação do pacote `accessibility` no seu site.

3.3 Cálculo de acessibilidade com o r5r

Ao longo das duas seções anteriores, nós mostramos como calcular níveis de acessibilidade passo-a-passo. Para fins didáticos, é importante entender que o cálculo de estimativas de aces-

sibilidade tem como primeiro passo a geração de uma matriz de custos de viagens a partir de simulações de roteamento, que posteriormente é utilizada para estimar níveis de acessibilidade.

No entanto, o `r5r` inclui também uma função chamada `accessibility()` que faz todo esse processamento com uma única chamada. De forma parecida com a função de cálculo de matriz de tempo de viagem, a função de acessibilidade também recebe como *inputs* uma conexão com o R5, as origens, os destinos, os modos de transporte, o tempo de partida, entre outros. Adicionalmente, devem ser listadas também quais oportunidades devem ser consideradas e a função de decaimento que deve ser utilizada (bem como o valor do limite de custo e de parâmetro de decaimento). O exemplo abaixo mostra uma aplicação desta função.

```
r5r_access <- accessibility(
  r5r_core,
  origins = points,
  destinations = points,
  opportunities_colname = "schools",
  decay_function = "step",
  cutoffs = 30,
  mode = c("WALK", "TRANSIT"),
  departure_datetime = as.POSIXct(
    "13-05-2019 14:00:00",
    format = "%d-%m-%Y %H:%M:%S"
  ),
  max_walk_dist = 800,
  max_trip_duration = 120,
  verbose = FALSE,
  progress = FALSE
)

r5r_access
```

```
             from_id percentile cutoff accessibility
   1: 89a901291abffff         50     30            17
   2: 89a9012a3cfffff         50     30             0
   3: 89a901295b7ffff         50     30            13
   4: 89a901284a3ffff         50     30             0
   5: 89a9012809bffff         50     30            17
  ---
1223: 89a90129133ffff         50     30             1
1224: 89a9012ac43ffff         50     30             8
1225: 89a90129a47ffff         50     30            10
```

```
1226: 89a90128883ffff          50      30             30
1227: 89a90166da7ffff          50      30             14
```

Como podemos observar, o resultado desta função são os níveis de acessibilidade já calculados. A informação "intermediária" de tempo de viagem entre origens e destinos, consequentemente, não fica disponível ao usuário com o uso da função. Ainda assim, este fluxo de trabalho pode ser uma boa alternativa para pessoas que estejam interessados puramente nos níveis de acessibilidade e não dependam do tempo de viagem em suas análises.

3.4 Análises de acessibilidade

Calculados os níveis de acessibilidade, procedemos então para sua análise. Existe uma grande variedade de análises que podem ser feitas usando esses dados, por exemplo de diagnóstico das condições de acessibilidade urbana de diferentes bairros, pesquisas sobre desigualdades de acesso a oportunidades entre diferentes grupos sociais, análises sobre exclusão social e *accessibility poverty* (insuficiência de acessibilidade, tradução livre), etc. Nesta seção, no entanto,nos restringiremos a apresentar duas análises relativamente simples e de fácil comunicação: a distribuição espacial da acessibilidade e sua distribuição entre diferentes grupos de renda.

Distribuição espacial de acessibilidade urbana

Para compreendermos a distribuição espacial da acessibilidade urbana de uma determinada cidade ou região, primeiro precisamos obter as informações espaciais dos pontos que foram utilizados como origens e destinos no cálculo da matriz. Os pontos que nós usamos nos exemplos anteriores, por exemplo, correspondem a células de uma grade hexagonal baseadas no índice H3, desenvolvido pela Uber (Brodsky 2018). O código e o mapa a seguir mostram a distribuição desses hexágonos na nossa área de estudo.

```
poa_grid <- read_grid("Porto Alegre")

poa_grid <- poa_grid[poa_grid$id_hex %in% points$id, ]

ggplot(poa_grid) + geom_sf()
```

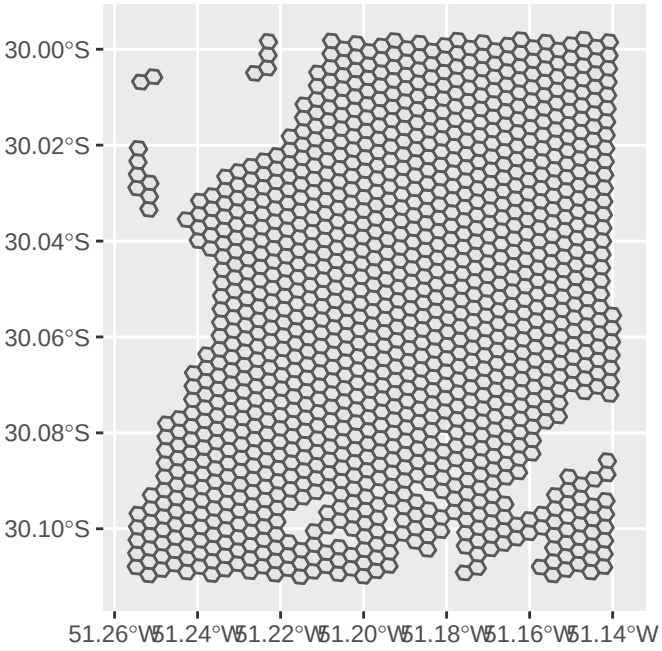

Para visualizarmos os nossos dados de acessibilidade espacialmente, portanto, nós precisamos unir a nossa tabela com estimativas de acessibilidade com a tabela que contém os dados espaciais da grade usando a coluna de `id` dos hexágonos como nossa coluna-chave. Os comandos usados para isso, bem como o resultado da operação em formato de imagem, podem ser vistos no código e no mapa a seguir.

```
setDT(poa_grid)
poa_grid[cumulative_access, on = c(id_hex = "id"), schools_access := i.schools]

poa_grid_sf <- st_sf(poa_grid)

ggplot(poa_grid_sf) +
  geom_sf(aes(fill = schools_access), color = NA) +
  scale_fill_viridis_c(option = "inferno")
```

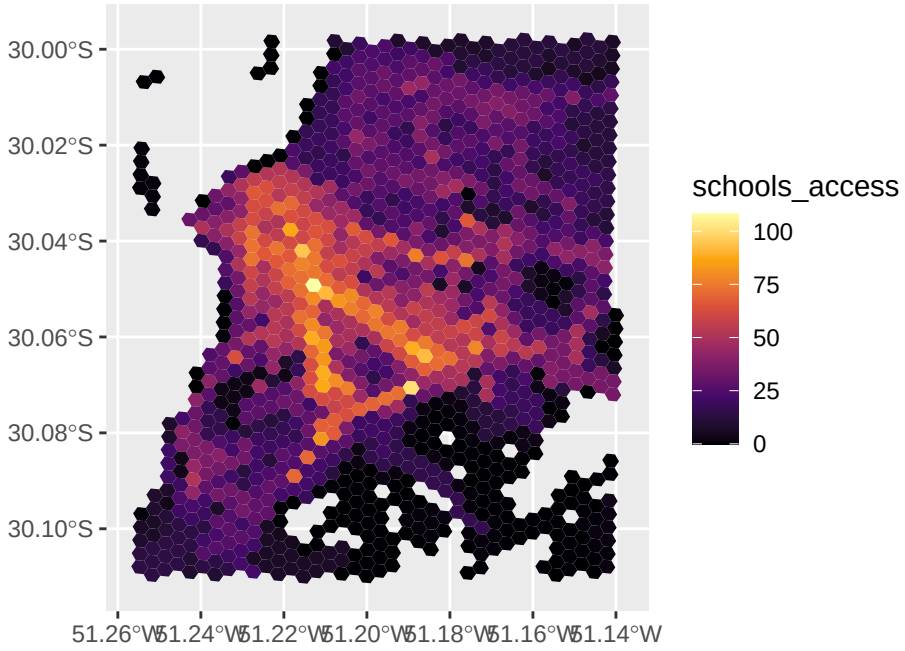

Como podemos ver, os níveis de acessibilidade tendem a se concentrar de forma mais acentuada no centro da cidade, onde existe maior concentração de empregos, e próximos aos grandes corredores de transportes da cidade. Pessoas que moram mais perto desses corredores tendem a gastar menos tempo no acesso a suas estações e conseguem acessar locais distantes relativamente rápido, por terem fácil acesso a modos de alta capacidade e velocidade. Pessoas que moram mais longe desses corredores, por sua vez, dependem de modos de menor velocidade operacional (como os ônibus municipais, por exemplo) e precisam gastar mais tempo para alcançar os corredores de média e alta capacidade. Como consequência, seus níveis de acessibilidade tendem a ser menores.

Distribuição socioeconômica de acessibilidade urbana

O mapa acima, embora revelador quanto aos locais em que estão dispostas as maiores concentrações de acessibilidade, nada diz sobre quais são os grupos socioeconômicos que possuem os maiores potenciais de acesso a oportunidades na região. Para isso, nós precisamos cruzar informações demográficas e econômicas de cada um dos nossos pontos de origem com os dados de acessibilidade previamente calculados. No exemplo abaixo, nós juntamos aos dados de acessibilidade a informação do decil de renda de cada uma das origens. Assim, nós conseguimos identificar se um hexágono é de baixa, média ou alta renda.

Os dados com as características socioeconômicas e perfil de renda que utilizamos no exemplo vêm do censo demográfico brasileiro de 2010, e foram agregados na grade espacial de dos hexágonos por (**pereira2022ususolo?**). Aqui, nós acessamos os dados diretamente de dentro do R usando o pacote `aopdata`, que será apresentado em mais detalhes no capítulo Xx.

```
poa_population <- read_population("Porto Alegre", showProgress = FALSE)

poa_grid[
  poa_population,
  on = "id_hex",
  `:=`(
    pop_count = i.P001,
    income_decile = i.R003
  )
]

poa_grid[, .(id_hex, schools_access, pop_count, income_decile)]
```

```
             id_hex schools_access pop_count income_decile
   1: 89a9012124fffff             14       733             9
   2: 89a9012126bffff             13       355             9
   3: 89a9012127bffff             14       996            10
   4: 89a90128003ffff             34      1742             4
   5: 89a90128007ffff             15       477             5
  ---
1218: 89a90e934cbffff              7       118             4
1219: 89a90e934cfffff             12       518             6
1220: 89a90e934d3ffff              5       846             6
1221: 89a90e934d7ffff             12      1615             7
1222: 89a90e934dbffff              6         0            NA
```

Como vocês podem perceber, nós também trouxemos a informação de contagem populacional em cada origem. Isto se dá porque nós iremos calcular a distribuição da acessibilidade de cada um dos decis de renda. Para isso, portanto, nós precisamos ponderar o nível de acessibilidade de cada origem pela quantidade de pessoas que residem ali. Desta forma, nós teremos a distribuição da acessibilidade das pessoas localizadas em origens de um determinado decil de renda. Caso optássemos por não ponderar, no entanto, nós teríamos a distribuição de acessibilidade não das pessoas localizadas em cada hexágono, mas dos hexágonos em si. Como em nossa análise nós nos importamos com as pessoas, e não com as células espaciais, precisamos fazer a ponderação. Nós podemos visualizar a distribuição de acessibilidade de cada decil usando um boxplot, como feito a seguir.

```
poa_grid[, income_decile := as.factor(income_decile)]

ggplot(poa_grid[!is.na(income_decile)]) +
  geom_boxplot(
```

```
    aes(
      x = income_decile,
      y = schools_access,
      color = income_decile,
      weight = pop_count
    )
  )
```

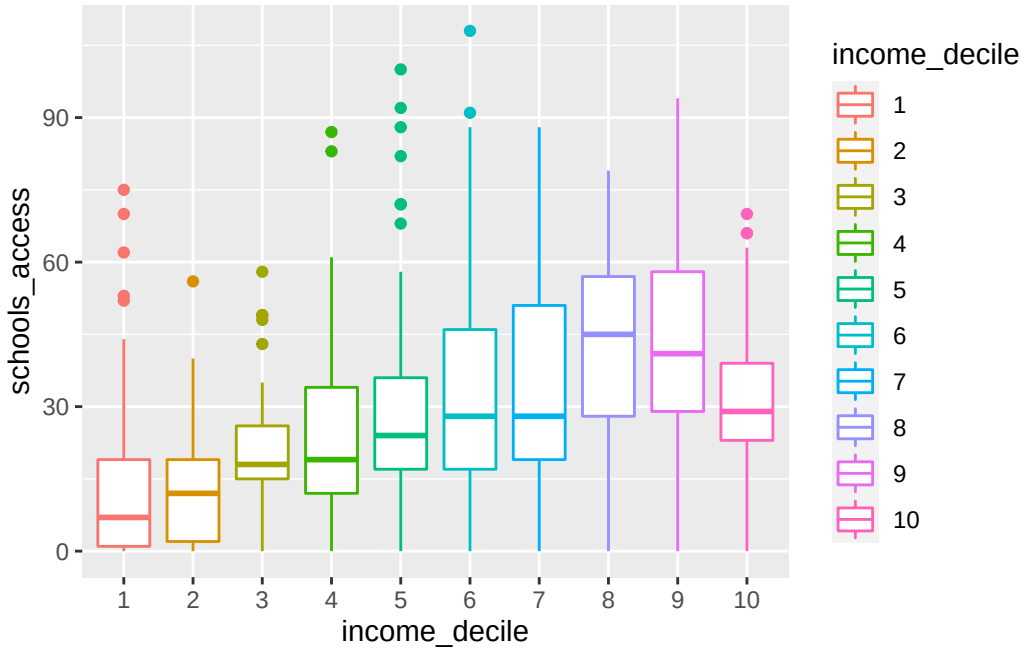

O gráfico é muito claro em seu conteúdo: pessoas de mais baixa renda tendem a ter níveis de acessibilidade muito menores do que as de alta renda. Isso é um padrão comum em praticamente todas as cidades brasileiras e em diversas cidades do mundo (**pereira2019desigualdades?**). Isto ocorre, em larga medida, devido à localização espacial das comunidades de baixa e alta renda no território: os mais ricos costumam morar em áreas mais valorizadas, próximas das grandes concentração de empregos (e oportunidades de educação, saúde, lazer, etc., também) e com maior oferta de transporte público de média e alta capacidade. Os mais pobres, por sua vez, tendem a morar em locais mais afastados, onde o valor da terra é menor. Consequentemente, tendem também a se afastar das grandes concentrações de oportunidades. Junta-se a isso o fato de, na maior parte dos casos, a oferta de serviços de transporte público de média e alta capacidade ser menor em locais com maior concentração de pessoas de baixa renda. Como consequência, seus níveis de acessibilidade são, em média, muito menores do que os dos mais ricos, como o gráfico deixa claro.

Part III

SEÇÃO 3: Dados de transporte público

Objetivo: O objetivo desta seção é (1) apresentar o que é a especificação de dados de transporte público em formato GTFS; e (2) apresentar como trabalhar e analisar dados de GTFS usando R.

Dados de transporte público são peças fundamentais no planejamento de transportes em geral, e em análises de acessibilidade em particular. Para serem usados de forma que se tenha segurança no resultado das análises, esses dados precisam ser confiáveis e de simples inspeção e interpretação.

Tentando satisfazer esses critérios, cada vez mais agências de transporte público, tomadores de decisão e pesquisadores têm buscado utilizar dados estruturados conforme especificações abertas e colaborativas - ou seja, cujo formato seja decidido por uma comunidade de atores interessados, incluindo partes que produzem esses dados (agências de transporte público, por exemplo) e que os consomem (pesquisadores, desenvolvedores de ferramentas de planejamento, etc.). Embora uma especificação aberta não necessariamente resolva o problema da qualidade e da confiabilidade dos dados por ela descritos, ela traz várias vantagens. O uso de um formato padrão de dados para transporte público permite o desenvolvimento e compartilhamento de ferramentas e programas computacionais para análise desses dados. Assim, um programa desenvolvido por agências de transporte para qualquer cidade no Brasil, Estados Unidos ou Japão pode ser facilmente utilizado para quaisquer cidades do mundo que também organizam seus dados naquele formato padrão. Além disso, quanto mais amplamente utilizado é esse formato padrão de dados, maior tende a ser tanto a confiabilidade da especificação em siquanto a facilidade inspeção dos dados e de sua interpretação, visto que múltiplos atores detêm o conhecimento necessário para tal.

A especificação de dados aberta e colaborativa mais amplamente utilizada no contexto do planejamento de transporte público é o formato GTFS, sigla para *General Transit Feed Specification* (Especificação Geral de Redes de Transporte Público, em tradução livre). Seus usos abrangem tanto o planejamento quanto a operação de sistemas de transporte público. Como visto no capítulo XX, os dados de GTFS também são uma peça fundamental para calcular estimativas de acessibilidade urbana por transporte público. Nesta seção nós iremos aprender em mais detalhe o que são os dados GTFS, como eles são estruturados e como trabalhar com esses dados no R.

4 Dados GTFS

O formato GTFS é uma especificação aberta e colaborativa que visa descrever os principais componentes de uma rede de transporte público. Atualmente, dados GTFS podem ser divididos em duas grandes categorias:

- *GTFS Schedule*, ou *GTFS Static*, que contém o cronograma estático de linhas de transporte público e informações espaciais sobre o itinerário de cada linha e suas paradas;
- *GTFS Realtime*, que contém informações de localização de veículos em tempo real e alertas de possíveis atrasos, de mudanças de percurso e de eventos que possam interferir no cronograma planejado.

Ao longo desta seção, nós focaremos no **GTFS Schedule**. Clique aqui para mais informações sobre o GTFS Realtime.

Por ser uma especificação aberta e colaborativa, o formato GTFS tenta abarcar em sua definição um grande número de usos distintos que agências de transporte e desenvolvedores de ferramentas possam dar a ele. No entanto, agências e *softwares* podem ainda assim depender de informações que não constem na especificação oficial. Surgem, dessa forma, extensões da especificação. Algumas dessas extensões podem eventualmente se tornar parte da especificação oficial, caso isto seja aceito pela comunidade de usuários do GTFS. Nesta seção nós focaremos em um subconjunto de informações presentes no formato GTFS Schedule "puro", e, portanto, não cobriremos suas extensões.

4.1 Estrutura dos arquivos de GTFS

Usualmente, refere-se a um arquivo no formato GTFS Schedule (daqui em diante chamado apenas de GTFS) como *feed*. Neste livro, nós utilizaremos os termos *feed* e arquivo GTFS como sinônimos.

Um *feed* é nada mais do que um arquivo comprimido em formato `.zip` que contém um conjunto de tabelas salvas em formato `.txt` com algumas informações sobre a rede de transporte público (e.g. localização das paradas, frequências das viagens, traçado das rotas etc). Como em uma base de dados relacional, as tabelas de um *feed* têm algumas colunas-chave que permitem vincular os dados rotas, viagens, tabelas de horários etc. O esquema geral do GTFS é mostrado na Figure 4.1, mostrando apenas algumas das principais tabelas e com as colunas-chave destacadas como os pontos finais das setas.

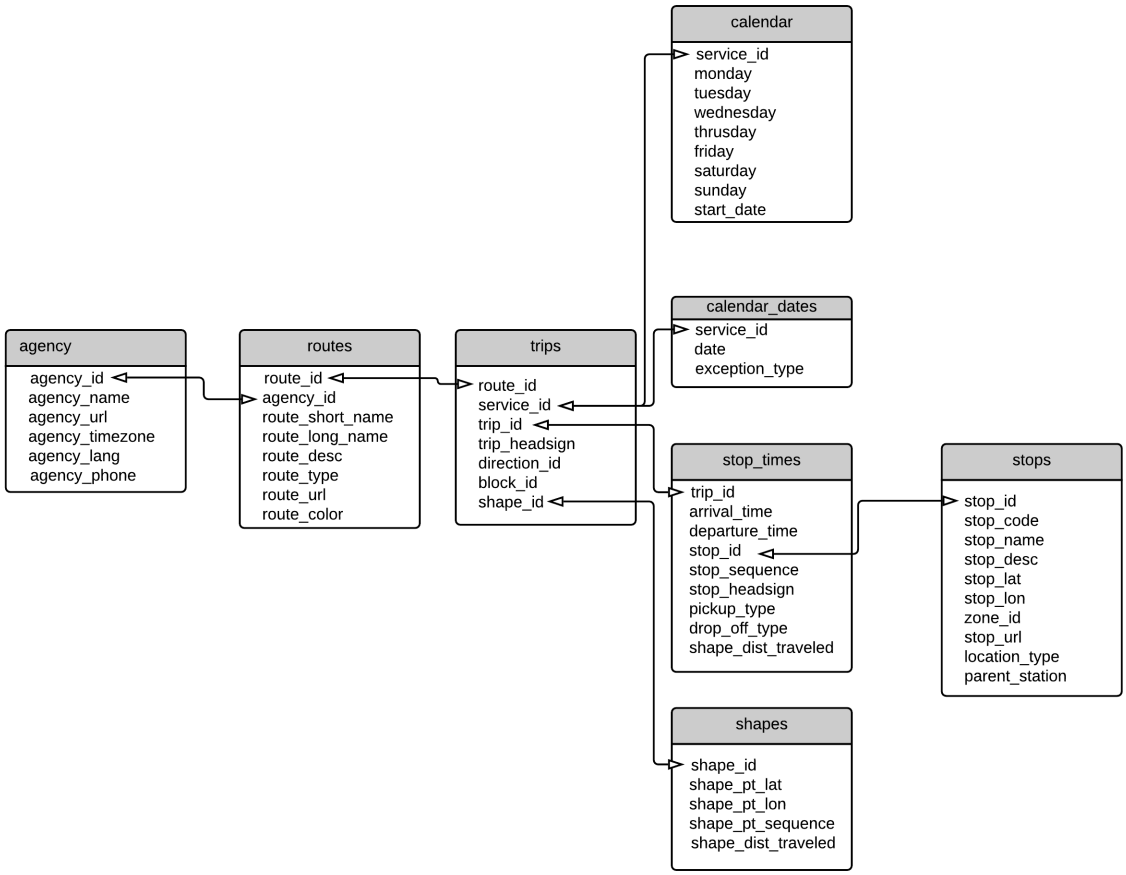

Figure 4.1: Esquema do formato GTFS

Ao todo, 22 tabelas compõem o formato GTFS[1]. Nem todas, no entanto, são obrigatórias para que um feed seja considerado válido - sendo consideradas, portanto, opcionais. A especificação classifica cada tabela conforme sua obrigatoriedade em três possíveis categorias: obrigatórias, opcionais e condicionalmente obrigatórias (quando a obrigatoriedade de uma tabela depende da existência de uma determinada tabela, coluna ou valor). Para fins de simplicidade, neste livro nós consideraremos apenas as duas primeiras categorias e faremos comentários quanto à obrigatoriedade de cada tabela quando apropriado. Desta forma, ficam assim classificadas as tabelas:

- Obrigatórias: `agency.txt`, `stops.txt`, `routes.txt`, `trips.txt`, `stop_times.txt`, `calendar.txt`.
- Opcionais: `calendar_dates.txt`, `fare_attributes.txt`, `fare_rules.txt`, `fare_products.txt`, `fare_leg_rules.txt`, `fare_transfer_rules.txt`, `areas.txt`, `stop_areas.txt`, `shapes.txt`, `frequencies.txt`, `transfers.txt`, `pathways.txt`, `levels.txt`, `translations.txt`, `feed_info.txt`, `attributions.txt`.

Ao longo desta seção, nós aprenderemos a estrutura básica de um arquivo GTFS e das tabelas que o compõem. Portanto, vamos olhar apenas para as tabelas obrigatórias e para as tabelas opcionais mais frequentemente utilizadas por produtores e consumidores desses arquivos. Para mais informações sobre as tabelas e as colunas não abordadas nesta seção, por favor verifique a especificação oficial.

Nesta demonstração, nós utilizaremos um subconjunto de dados provenientes do *feed* da cidade de São Paulo criado pela SPTrans[2] e baixado em outubro de 2019. O *feed* contém as seis tabelas obrigatórias e mais duas tabelas opcionais bastante utilizadas, `shapes.txt` e `frequencies.txt`, o que permite uma boa visão geral sobre o formato GTFS.

4.1.1 agency.txt

Arquivo utilizado para descrever as operadoras de transporte que atuam no sistema descrito no arquivo GTFS. Embora o termo *agency* (agência) seja usado em lugar de *operators* (operadoras), por exemplo, fica a cargo do produtor do *feed* definir quais instituições serão listadas na tabela.

Por exemplo: múltiplas concessionárias de ônibus atuam em um determinado local, mas todo o planejamento de cronograma e de tarifa é realizado por uma instituição, em geral uma secretaria de transporte ou empresa pública específica. Esta instituição é também entendida pelos usuários do sistema como a operadora, de fato. Neste caso, devemos listar a instituição responsável pelo planejamento na tabela.

[1] Disponível em https://github.com/ipeaGIT/gtfstools.

[2] Mais detalhes sobre o uso e a sintaxe do `data.table` podem ser lidos em https://rdatatable.gitlab.io/data.table/index.html.

Agora, imagine um sistema em que a agência de transporte público local transfere a responsabilidade da operação de um sistema multimodal a diversas empresas, por meio de concessões. Cada uma dessas empresas é responsável pelo planejamento de cronogramas e tarifas dos modos que operam, desde que sejam seguidos determinados parâmetros pré-estabelecidos em contrato. Neste caso, devemos listar as operadoras (concessionárias) na tabela, e não a agência de transporte público em si.

A Table 4.1 mostra o arquivo `agency.txt` do *feed* da SPTrans. Como vocês podem ver, os responsáveis pelo *feed* optaram por listar a própria empresa no arquivo, e não as concessionárias que operam os ônibus e o metrô da cidade.

Table 4.1: Exemplo de arquivo `agency.txt`

agency_id	agency_name	agency_url	agency_timezone	agency_lang
1	SPTRANS	http://www.sptrans.com.br/?versao=011019	America/Sao_Paulo	pt

É necessário notar que, embora estejamos apresentando o `agency.txt` em formato de tabela, o arquivo deve ser formatado como se fosse salvo em formato `.csv`. Ou seja, os valores de cada célula da tabela devem ser separados por vírgulas, e cada linha da tabela deve constar em uma linha no arquivo. A tabela acima, por exemplo, é definida da seguinte forma:

```
agency_id,agency_name,agency_url,agency_timezone,agency_lang
1,SPTRANS,http://www.sptrans.com.br/?versao=011019,America/Sao_Paulo,pt
```

Por uma questão de comunicação e interpretação dos dados, ao longo desta seção sempre apresentaremos os exemplos em formato de tabela. É importante ter em mente, porém, que essas tabelas são internamente estruturadas como mostrado acima.

4.1.2 stops.txt

Arquivo usado para descrever as paradas de transporte público que compõem o sistema. Os pontos listados neste arquivo podem fazer menção a paradas mais simples (como pontos de ônibus), estações, plataformas, entradas e saídas de estações, etc. A Table 4.2 mostra o `stops.txt` do *feed* da SPTrans.

Table 4.2: Exemplo de arquivo `stops.txt`

stop_id	stop_name	stop_desc	stop_lat	stop_lon
706325	Parada 14 Bis B/C	Viad. Dr. Plínio De Queiroz, 901	-23.55593	-46.65011

stop_id	stop_name	stop_desc	stop_lat	stop_lon
810602	R. Sta. Rita, 56	Ref.: R. Bresser / R. João Boemer	-23.53337	-46.61229
910776	Av. Do Estado, 5854	Ref.: Rua Dona Ana Néri	-23.55896	-46.61520
1010092	Parada Caetano Pinto	Av. Rangel Pestana, 1249 Ref.: Rua Caetano Pinto/rua Prof. Batista De Andrade	-23.54615	-46.62218
1010093	Parada Piratininga	Av. Rangel Pestana, 1479 Ref.: Rua Monsenhor Andrade	-23.54509	-46.62006
1010099	R. Xavantes, 612	Ref.: Rua Joli	-23.53545	-46.61368

As colunas `stop_id` e `stop_name` servem como identificadores de cada parada, porém cumprem papéis distintos. O principal propósito da `stop_id` é identificar relações entre esta tabela e outras que compõem a especificação (como veremos mais à frente no arquivo `stop_times.txt`). Já a coluna `stop_name` serve como um identificador que seja facilmente reconhecido pelo usuário do sistema. Seus valores, portanto, costumam ser nomes de estações, nomes de pontos de interesse da cidade ou endereços (como no caso do *feed* da SPTrans).

A coluna `stop_desc`, presente no *feed* da SPTrans, é opcional e permite à agência de transporte adicionar alguma descrição de cada parada e do seu entorno para facilitar a sua identificação. As colunas `stop_lat` e `stop_lon`, por fim, são as responsáveis por associar cada parada a uma posição espacial, através de suas coordenadas geográficas de latitude e longitude.

Entre as colunas opcionais não presentes neste feed estão a `location_type` e a `parent_station`. A `location_type` é utilizada para denotar o tipo de localização a que cada ponto se refere. Quando ausente, todos os pontos são interpretados como paradas de transporte público, mas valores distintos podem ser usados para distinguir uma parada (`location_type = 0`) de uma estação (`location_type = 1`) ou uma área de embarque (`location_type = 2`), por exemplo. A coluna `parent_station` é utilizada para descrever relações de hierarquia entre dois pontos. Por exemplo, uma área de desembarque deve dizer a qual parada/plataforma ela pertence e uma parada/plataforma pode também, opcionalmente, listar a qual estação ela pertence.

4.1.3 routes.txt

Arquivo usado para descrever as linhas de transporte público que rodam no sistema descrito pelo arquivo GTFS, incluindo os modos de transporte utilizados em cada uma. A Table 4.3 mostra o `routes.txt` do *feed* da SPTrans.

Table 4.3: Exemplo de arquivo `routes.txt`

route_id	agency_id	route_short_name	route_long_name	route_type
CPTM L07	1	CPTM L07	JUNDIAI - LUZ	2
CPTM L08	1	CPTM L08	AMADOR BUENO - JULIO PRESTES	2
CPTM L09	1	CPTM L09	GRAJAU - OSASCO	2
CPTM L10	1	CPTM L10	RIO GRANDE DA SERRA - BRÁS	2
CPTM L11	1	CPTM L11	ESTUDANTES - LUZ	2
CPTM L12	1	CPTM L12	CALMON VIANA - BRAS	2

Assim como no caso do arquivo `stops.txt`, a tabela do `routes.txt` também possui diferentes colunas que apontam o identificador de cada linha (`route_id`) e o seu nome. Neste caso, no entanto, existem duas colunas de nome, a `route_short_name` e a `route_long_name`. A primeira diz respeito ao nome da linha, usualmente utilizado por passageiros no dia-a-dia, enquanto o segundo tende a ser um nome mais descritivo. A SPTrans, por exemplo, optou por destacar os pontos finais de cada linha nesta coluna. Podemos notar também que os mesmos valores se repetem nas colunas `route_id` e `route_short_name`, o que não é obrigatório e nem proibido - neste caso, o produtor do *feed* julgou que os nomes das linhas poderiam funcionar satisfatoriamente como identificadores por serem razoavelmente curtos e não se repetirem.

A coluna `agency_id` é a chave que permite relacionar a tabela das rotas com a tabela descrita no `agency.txt`. Ela faz menção a uma agência descrita naquele arquivo, no caso a agência de id 1 (a própria SPTrans). Esta coluna é opcional no caso de *feeds* em que existe apenas uma agência, porém é obrigatória no caso em que existem mais de uma. Imaginemos, por exemplo, um feed que descreve um sistema multimodal que conta com um corredor de metrô e diversas linhas de ônibus: uma configuração possível de routes.txt descreveria as linhas de metrô como de responsabilidade da operadora do metrô, e as de ônibus como de responsabilidade da empresa responsável pelo planejamento das linhas de ônibus, por exemplo.

A coluna `route_type` é utilizada para descrever o modo de transporte utilizado em cada linha. Esta coluna aceita diferentes números, cada um representando um determinado modo. Este exemplo descreve linhas de trem, cujo valor numérico correspondente é 2. Os valores válidos para esta coluna são listados na especificação.

4.1.4 trips.txt

Arquivo usado para descrever as viagens realizadas pelo sistema de transporte público descrito pelo *feed*. A viagem é a unidade básica de movimento do formato GTFS: ela associa diferentes partidas de cada linha de transporte público a um serviço que opera em determinados dias da semana (como veremos mais à frente no arquivo `calendar.txt`) e uma trajetória de viagem (como veremos mais à frente no arquivo `shapes.txt`). A Table 4.4 mostra o `trips.txt` do *feed* da SPTrans.

Table 4.4: Exemplo de arquivo `trips.txt`

trip_id	route_id	service_id	trip_headsign	direction_id	shape_id
CPTM L07-0	CPTM L07	USD	JUNDIAI	0	17846
CPTM L07-1	CPTM L07	USD	LUZ	1	17847
CPTM L08-0	CPTM L08	USD	AMADOR BUENO	0	17848
CPTM L08-1	CPTM L08	USD	JULIO PRESTES	1	17849
CPTM L09-0	CPTM L09	USD	GRAJAU	0	17850
CPTM L09-1	CPTM L09	USD	OSASCO	1	17851

A coluna `trip_id` identifica cada uma das viagens descritas na tabela. A `route_id` faz referência a uma linha de transporte público identificada no arquivo `routes.txt`. A coluna `service_id` identifica serviços que determinam os dias da semana em que cada uma das viagens opera (dias úteis, finais de semana, uma mistura dos dois, etc.), descritos detalhadamente no arquivo `calendar.txt`. A última coluna à direita na tabela acima é a `shape_id`, que identifica a trajetória espacial de cada uma das viagens, descrita em detalhes no arquivo `shapes.txt`.

As duas colunas restantes, `trip_headsign` e `direction_id`, são opcionais e devem ser utilizadas para descrever o sentido/destino da viagem. A primeira, `trip_headsign`, é utilizada para ditar o texto que aparece no letreiro de veículos (no caso de um ônibus, por exemplo) ou em painéis informativos (como em metrôs e trens) destacando o destino da viagem. Já a coluna `direction_id` é frequentemente utilizada em conjunto com a primeira para dar uma conotação de ida ou volta para cada viagem, onde `0` representa ida e `1` volta, ou vice-versa (assim como ida e volta são conceitos que mudam conforme o referencial, os valores `0` e `1` podem ser usados como desejado, desde que um represente um sentido e o outro o contrário). No caso do nosso exemplo, as duas primeiras linhas são viagens que fazem menção à mesma

rota de transporte público (`CPTM L07`), porém em sentidos opostos: uma corre em direção a Jundiaí, e a outra à Luz.

4.1.5 calendar.txt

Arquivo usado para descrever os diferentes tipos de serviço existentes no sistema de transporte público descrito pelo *feed*. Um serviço, neste contexto, denota um conjunto de dias da semana em que viagens são realizadas. Cada serviço também é definido pela data em que começa a valer e pela data a partir do qual ele não é mais válido. A Table 4.5 mostra o `calendar.txt` do *feed* da SPTrans.

Table 4.5: Exemplo de arquivo `calendar.txt`

service_id	monday	tuesday	wednesday	thursday	friday	saturday	sunday	start_date	end_date
USD	1	1	1	1	1	1	1	20080101	20200501
U___	1	1	1	1	1	0	0	20080101	20200501
US_	1	1	1	1	1	1	0	20080101	20200501
_SD	0	0	0	0	0	1	1	20080101	20200501
___D	0	0	0	0	0	0	1	20080101	20200501
S	0	0	0	0	0	1	0	20080101	20200501

A coluna `service_id` identifica cada um dos serviços descritos na tabela. Como mostrado anteriormente, este identificador é usado também no arquivo `trips.txt`, e é o responsável por associar cada viagem a um determinado serviço.

As colunas `monday`, `tuesday`, `wednesday`, `thursday`, `friday`, `saturday` e `sunday` (segunda-feira a domingo, em inglês) são utilizadas para delimitar os dias em que cada serviço funciona. Um valor de `1` significa que o serviço opera em um determinado dia, enquanto um valor de `0` significa que ele não opera. Como podemos ver no exemplo acima, o serviço `USD` opera em todos os dias da semana. Já o serviço `U__` opera apenas em dias úteis.

Por fim, as colunas `start_date` e `end_date` delimitam o intervalo em que cada serviço é válido. As datas do formato GTFS são sempre formatadas segundo a regra `YYYYMMDD` - ou seja, os primeiros quatro números definem o ano, os dois subsequentes definem o mês e os últimos dois, o dia. O valor `20220428`, por exemplo, representa o dia 28 de abril de 2022.

4.1.6 shapes.txt

Arquivo usado para descrever a trajetória espacial de cada viagem listada no *feed*. Este arquivo é opcional, mas fortemente recomendado que agências de transporte o incluam em seus arquivos de GTFS. A Table 4.6 mostra o `shapes.txt` do *feed* da SPTrans.

Table 4.6: Exemplo de arquivo `shapes.txt`

shape_id	shape_pt_lat	shape_pt_lon	shape_pt_sequence
17846	-23.53517	-46.63535	1
17846	-23.53513	-46.63548	2
17846	-23.53494	-46.63626	3
17846	-23.53473	-46.63710	4
17846	-23.53466	-46.63735	5
17846	-23.53416	-46.63866	6

A coluna `shape_id` identifica cada uma das trajetórias descritas na tabela. Como mostrado anteriormente, este identificador é usado também no arquivo `trips.txt`, e é o responsável por associar cada viagem à sua trajetória espacial. Diferentemente de todos os outros identificadores que vimos até então, no entanto, o identificador `shape_id` se repete em diversas observações da tabela. Isso porque o arquivo apresenta para cada `shape_id` uma série de pontos espaciais, cujas coordenadas geográficas são apresentadas nas colunas `shape_pt_lat` e `shape_pt_lon`. Por sua vez, a coluna `shape_pt_sequence` lista a sequência na qual cada ponto se conecta para formar a trajetória de cada `shape_id`. Os valores listados nesta coluna devem ser ordenados de forma crescente.

4.1.7 stop_times.txt

Arquivo usado para descrever o cronograma com tabela de horários de cada viagem, incluindo o horário de chegada e partida em cada uma das paradas. A formatação deste arquivo depende da existência ou não de um arquivo `frequencies.txt`, o qual cobriremos a seguir. Por enquanto olharemos para o `stop_times.txt` do *feed* da SPTrans, que também conta com um `frequencies.txt`, na Table 4.7.

Table 4.7: Exemplo de arquivo `stop_times.txt`

trip_id	arrival_time	departure_time	stop_id	stop_sequence
CPTM L07-0	04:00:00	04:00:00	18940	1
CPTM L07-0	04:08:00	04:08:00	18920	2
CPTM L07-0	04:16:00	04:16:00	18919	3
CPTM L07-0	04:24:00	04:24:00	18917	4
CPTM L07-0	04:32:00	04:32:00	18916	5
CPTM L07-0	04:40:00	04:40:00	18965	6

A viagem cujo cronograma está sendo descrito é identificada pela coluna `trip_id`. De forma análoga ao que acontece na tabela de trajetórias, um mesmo `trip_id` se repete em muitas

observações da tabela porque, assim como uma trajetória é composta por uma sequências de pontos espaciais, um cronograma é composto por uma sequência de diversos horários de partida/chegada e paradas de transporte público.

As colunas seguintes, `arrival_time`, `departure_time` e `stop_id`, são as responsáveis por descrever o cronograma em si, associando um horário de chegada e um horário de partida para cada uma das paradas visitadas na viagem. As colunas de horário são formatadas segundo a regra `HH:MM:SS` - ou seja, os dois primeiros números definem a hora, os dois subsequentes os minutos e os últimos dois, os segundos. É importante ainda comentar que esta formatação aceita valores de hora maiores do que `24`. Isto quer dizer que uma viagem cuja última parada seja visitada às 1h da manhã do dia seguinte ao que começou a rodar (digamos que ela tenha partido do ponto inicial às 23h) deve ter como horário de chegada `25:00:00`, e não `01:00:00`. A coluna `stop_id`, por sua vez, associa a parada visitada à uma descrição feita no arquivo `stops.txt`. Por fim, a coluna `stop_sequence` lista a sequência na qual cada parada se conecta às demais para formar o cronograma da viagem. Seus valores devem ser sempre ordenados de forma crescente.

Vale destacar aqui a diferença entre os arquivos `shapes.txt` e `stop_times.txt`. Embora os dois descrevam uma viagem espacialmente, eles o fazem de forma diferente. O `stop_times.txt` descreve a sequência de paradas e horários que compõem um cronograma, mas nada diz sobre o trajeto percorrido pelo veículo entre cada uma das paradas. Já o `shapes.txt` traz a trajetória da viagem como um todo, mas não descreve em que ponto do espaço estão as paradas da viagem. Quando usamos os dois arquivos em conjunto, portanto, sabemos não apenas o cronograma de cada viagem, mas também a trajetória da viagem entre paradas.

4.1.8 frequencies.txt

Arquivo opcional usado para descrever a frequência de cada viagem dentro de um determinado período do dia. A Table 4.8 mostra o `frequencies.txt` do *feed* da SPTrans.

Table 4.8: Exemplo de arquivo `frequencies.txt`

trip_id	start_time	end_time	headway_secs
CPTM L07-0	04:00:00	04:59:00	720
CPTM L07-0	05:00:00	05:59:00	360
CPTM L07-0	06:00:00	06:59:00	360
CPTM L07-0	07:00:00	07:59:00	360
CPTM L07-0	08:00:00	08:59:00	360
CPTM L07-0	09:00:00	09:59:00	480

A viagem cuja frequência está sendo descrita é identificada pela coluna `trip_id`. Novamente, um mesmo id pode aparecer em várias observações da tabela. Isso porque a especificação

GTFS prevê que uma mesma viagem pode ter frequências diferentes ao longo do dia (como em horários de pico e fora-pico, por exemplo). Assim, cada linha da tabela descreve um período do dia que se inicia no horário descrito na coluna `start_time` e termina no horário assinalado na `end_time`.

Dentro do período especificado por essas duas colunas a viagem possui um *headway* detalhado na coluna `headway_secs`. O *headway* é o tempo que separa a passagem de dois veículos que operam a mesma linha de transporte público. No caso desta tabela, esse tempo deve ser especificado em segundos. Um valor de `720` entre 04:00h e 05:00h, portanto, significa que dentro deste período a viagem `CPTM L07-0` ocorre de 12 em 12 minutos.

É importante entender, agora, como a presença da tabela `frequencies.txt` altera a especificação da tabela `stop_times.txt`. Como podemos ver no nosso exemplo, o horário de partida definido no `stop_times.txt` para a viagem `CPTM L07-0` é 04:00h, e ela chega na segunda parada às 04:08h. O cronograma de chegada e saída de uma mesma parada de uma viagem, no entanto, não pode ser definido mais de uma vez na tabela. Como então definir o cronograma das viagens que partem às 04:12h, 04:24h, 04:36h, etc. (lembrem-se que o *headway* desta viagem é de 12 minutos)?

No caso em que a frequência de uma viagem é especificada no `frequencies.txt`, o cronograma (a tabela de horários) de uma viagem definido no `stop_times.txt` deve ser entendido como uma referência que descreve o tempo entre paradas. Isto é, os horários ali definidos não devem ser interpretados à risca. Por exemplo, o cronograma listado estabelece que o tempo de viagem entre a primeira e a segunda parada é de 8 minutos, e o tempo entre a segunda e a terceira também. Ou seja, a viagem que parte da primeira parada às 04:00h chega na segunda às 04:08h, e na terceira às 04:16h. A próxima viagem, que parte da primeira parada às 04:12h, por sua vez, chega na segunda parada às 04:20h, e na terceira às 04:28h.

Assumindo partidas de 12 em 12 minutos a partir das 04:00h, por exemplo, poderíamos descrever as mesmas viagens no `stop_times.txt` sem fazer uso do arquivo `frequencies.txt`. Para isso poderíamos adicionar um sufixo que identificasse cada uma das viagens referentes à linha (`route_id`) com identificador `CPTM L07` ao longo do dia. A viagem (`trip_id`) com identificador `CPTM L07-0_1`, por exemplo, seria a primeira viagem do dia e partiria da primeira parada às 04:00h e chegaria na segunda parada às 04:08h. A viagem `CPTM L07-0_2`, por sua vez, seria a segunda viagem e partiria da primeira parada às 04:12h e chegaria na segunda às 04:20h, e daí em diante. Cada uma dessas viagens deveria ser também adicionada ao arquivo `trips.txt` e a quaisquer outros que possuam a coluna `trip_id` como identificador.

Outra variável que afeta a forma na qual o `frequencies.txt` afeta as tabelas de horários na tabela `stop_times.txt` é a coluna opcional `exact_times`. Um valor de `0` nesta coluna (ou quando ela está ausente do *feed*, como no caso do arquivo GTFS da SPTrans) indica que a viagem não necessariamente segue um cronograma fixo ao longo do período. Ao invés disso, operadores tentam se ater a um determinado *headway* durante o período. Naquele exemplo de uma viagem cujo *headway* é de 12 minutos entre as 04:00h e 05:00h, isto significaria que não necessariamente a primeira partida sairá exatamente às 04:00h, a segunda às 04:12h, e por aí

em diante. A primeira pode, por exemplo, sair às 04:02h. A segunda, às 04:14h ou 04:13h, etc. Caso desejemos definir um cronograma que é seguido à risca, obtendo o mesmo resultado de definir diversas viagens semelhantes partindo em diferentes horários no `stop_times.txt` (como mostrado anteriormente), devemos utilizar o valor `1` na coluna `exact_times`.

4.2 Onde encontrar GTFS de cidades brasileiras

No Brasil, existem dados de GTFS para diversas cidades. Em muitos casos, no entanto, esses dados são de propriedade de empresas operadoras e concessionárias de transporte, e não do poder público. Infelizmente, esses arquivos raramente são disponibilizados aberta e publicamente, contrariando boas práticas de gestão e compartilhamento de dados de interesse público. A Table 4.9 mostra as fontes dos dados GTFS de algumas das poucas cidades do Brasil que disponibilizavam seus feeds abertamente no momento desta publicação.

Table 4.9: Fontes de dados GTFS publicamente disponíveis no Brasil

Cidade	Fonte	Informações
Belo Horizonte	BHTrans	Dado aberto: transporte convencional; transporte suplementar.
Fortaleza	ETUFOR	Dado aberto.
Fortaleza	Metrofor	Dado aberto.
Porto Alegre	EPTC	Dado aberto.
Rio de Janeiro	SMTR	Dado aberto.
São Paulo	EMTU	Download neste link. Necessário cadastro.
São Paulo	SPTrans	Download neste link. Necessário cadastro.

Obs. Os dados de GTFS disponibilizados para Rio de Janeiro e Porto Alegre não necessariamente cobrem todos os modos de transporte público disponíveis nessas cidades.

5 Manipulação e visualização de dados GTFS

Usualmente, arquivos GTFS oriundos de bases oficiais são utilizados para desenvolver análises e pesquisas que possuem diversos elementos comuns. Visando facilitar a leitura, o processamento e a análise desses dados, a equipe do Projeto Acesso a Oportunidades vêm desenvolvendo o pacote de R `gtfstools`[1], que oferece diversas funções que facilitam a manipulação e a exploração de feeds.

Neste capítulo, nós iremos passar por algumas das funcionalidades mais frequentemente utilizadas do pacote. Para isso, vamos utilizar uma amostra do *feed* da SPTrans apresentado no capítulo anterior, disponível dentro do `gtfstools`.

5.1 Leitura e manipulação básica de arquivos GTFS

A leitura de arquivos GTFS com o `gtfstools` é feita com a função `read_gtfs()`, que recebe uma *string* com o caminho do arquivo. Um *feed* é representado como uma lista de `data.table`s, uma versão de alta performance da classe `data.frame`. Ao longo deste capítulo, nós vamos nos referir a esta lista de tabelas como um **objeto GTFS**. Por padrão, a função lê todas as tabelas `.txt` do *feed*:

```
library(gtfstools)

path <- system.file("extdata/spo_gtfs.zip", package = "gtfstools")

gtfs <- read_gtfs(path)

names(gtfs)
```

```
[1] "agency"      "calendar"    "frequencies" "routes"      "shapes"
[6] "stop_times"  "stops"       "trips"
```

Como podemos ver, cada `data.table` dentro do objeto GTFS é nomeado de acordo com a tabela que ele representa, porém sem a extensão `.txt`. Isso nos permite selecionar e manipular

[1] Disponível em https://github.com/ipeaGIT/gtfstools.

cada uma das tabelas separadamente. O código abaixo, por exemplo, mostra os 6 primeiros registros da tabela *trips*:

```
head(gtfs$trips)
```

```
   route_id service_id    trip_id trip_headsign direction_id shape_id
1: CPTM L07        USD CPTM L07-0       JUNDIAI            0    17846
2: CPTM L07        USD CPTM L07-1           LUZ            1    17847
3: CPTM L08        USD CPTM L08-0  AMADOR BUENO            0    17848
4: CPTM L08        USD CPTM L08-1 JULIO PRESTES            1    17849
5: CPTM L09        USD CPTM L09-0        GRAJAU            0    17850
6: CPTM L09        USD CPTM L09-1        OSASCO            1    17851
```

As tabelas dentro de um objeto GTFS podem ser facilmente manipuladas usando a sintaxe de tabelas `data.table`. O pacote data.table oferece diversas funcionalidades úteis, como a edição de colunas por referência, filtros de linhas muito rápidos e agregação de dados eficiente[2]. Para adicionar 100 segundos a todos os *headways* listados na tabela *frequencies* e reverter essa mudança em seguida, por exemplo, nós podemos usar o código abaixo:

```
# original
original_headway <- gtfs$frequencies$headway_secs
head(gtfs$frequencies, 3)
```

```
      trip_id start_time end_time headway_secs
1: CPTM L07-0   04:00:00 04:59:00          720
2: CPTM L07-0   05:00:00 05:59:00          360
3: CPTM L07-0   06:00:00 06:59:00          360
```

```
# modified
gtfs$frequencies[, headway_secs := headway_secs + 100]
head(gtfs$frequencies, 3)
```

```
      trip_id start_time end_time headway_secs
1: CPTM L07-0   04:00:00 04:59:00          820
2: CPTM L07-0   05:00:00 05:59:00          460
3: CPTM L07-0   06:00:00 06:59:00          460
```

[2]Mais detalhes sobre o uso e a sintaxe do `data.table` podem ser lidos em https://rdatatable.gitlab.io/data.table/index.html.

```
# back to original
gtfs$frequencies[, headway_secs := original_headway]
head(gtfs$frequencies, 3)
```

```
      trip_id start_time end_time headway_secs
1: CPTM L07-0   04:00:00 04:59:00          720
2: CPTM L07-0   05:00:00 05:59:00          360
3: CPTM L07-0   06:00:00 06:59:00          360
```

Ao final de edições de um objeto GTFS no R, frequentemente vamos querer usar o GTFS manipulado para fazer análises de diferentes tipos. Para isso, é comum que precisemos do arquivo GTFS em formato `.zip` novamente, e não da lista de tabelas dentro do R. O pacote disponibiliza a função `write_gtfs()` exatamente com a finalidade de transformar objetos GTFS que existem apenas dentro do R em arquivos GTFS salvos na memória de seu computador. Para usá-la, é necessário apenas listar o objeto e o endereço no qual ele deve ser salvo:

```
dest_path <- tempfile("new_gtfs", fileext = ".zip")

file.exists(dest_path)
```

```
[1] FALSE
```

```
write_gtfs(gtfs, dest_path)

file.exists(dest_path)
```

```
[1] TRUE
```

```
zip::zip_list(dest_path)[, c("filename", "compressed_size", "timestamp")]
```

```
         filename compressed_size           timestamp
1      agency.txt             112 2022-09-29 20:34:16
2    calendar.txt             129 2022-09-29 20:34:16
3 frequencies.txt            2381 2022-09-29 20:34:16
4      routes.txt             659 2022-09-29 20:34:16
5      shapes.txt          160470 2022-09-29 20:34:16
6   stop_times.txt            7907 2022-09-29 20:34:16
7       stops.txt           18797 2022-09-29 20:34:16
8       trips.txt             717 2022-09-29 20:34:16
```

5.2 Cálculo de velocidade das linhas

Arquivos GTFS são frequentemente utilizados em estimativas de roteamento de transporte público e para informar passageiros sobre a tabela de horários das diferentes rotas que operam em uma região. Dessa forma, é extremamente importante que o cronograma das viagens e a velocidade operacional de cada linha estejam adequadamente descritos no *feed*.

O `gtfstools` disponibiliza a função `get_trip_speed()` para facilitar o cálculo da velocidade de cada viagem presente no *feed*. Por padrão a função retorna a velocidade (em km/h) de todas as viagens do GTFS, mas viagens individuais também podem ser especificadas:

```
speeds <- get_trip_speed(gtfs)

head(speeds)
```

```
     trip_id origin_file     speed
1: 2002-10-0      shapes  8.952511
2: 2105-10-0      shapes 10.253365
3: 2105-10-1      shapes  9.795292
4: 2161-10-0      shapes 11.182534
5: 2161-10-1      shapes 11.784458
6: 4491-10-0      shapes 13.203560
```

```
nrow(speeds)
```

```
[1] 36
```

```
speeds <- get_trip_speed(gtfs, trip_id = c("CPTM L07-0", "2002-10-0"))

speeds
```

```
      trip_id origin_file     speed
1:  2002-10-0      shapes  8.952511
2: CPTM L07-0      shapes 26.787768
```

Calcular a velocidade de uma viagem requer que nós saibamos o seu comprimento e em quanto tempo ela foi realizada. Para isso, portanto, a `get_trip_speed()` utiliza duas outras funções

do `gtfstools` por trás dos panos: a `get_trip_length()` e a `get_trip_duration()`. O funcionamento das duas é muito parecido com o mostrado anteriormente, retornando o comprimento/duração de todas as viagens por padrão, ou de apenas algumas selecionadas, caso desejado. Abaixo nós mostramos seus comportamentos padrões:

```
length <- get_trip_length(gtfs, file = "shapes")

head(length)
```

```
      trip_id   length origin_file
1: CPTM L07-0 60.71894      shapes
2: CPTM L07-1 60.71894      shapes
3: CPTM L08-0 41.79037      shapes
4: CPTM L08-1 41.79037      shapes
5: CPTM L09-0 31.88906      shapes
6: CPTM L09-1 31.88906      shapes
```

```
duration <- get_trip_duration(gtfs)

head(duration)
```

```
     trip_id duration
1: 2002-10-0       48
2: 2105-10-0      108
3: 2105-10-1      111
4: 2161-10-0       94
5: 2161-10-1       93
6: 4491-10-0       69
```

Assim como a `get_trip_speed()` retorna velocidades em km/h por padrão, a `get_trip_length()` retorna os comprimentos em km e a `get_trip_duration()` retorna a duração em minutos. Essas unidades podem ser ajustadas com o argumento `unit`, presente em todas as funções.

5.3 Combinação e filtragem de *feeds*

Muitas vezes o processo de processamento e edição de arquivos GTFS é realizado, em grande medida, manualmente. Consequentemente, pequenas inconsistências podem passar batidas pelos responsáveis por esse processamento. Um problema comumente observado em *feeds* é

a presença de registros duplicados em uma mesma tabela. O *feed* da SPTrans, por exemplo, possui registros duplicados tanto no *agency.txt* quanto no *calendar.txt*:

```
gtfs$agency
```

```
   agency_id agency_name                                agency_url
1:         1     SPTRANS http://www.sptrans.com.br/?versao=011019
2:         1     SPTRANS http://www.sptrans.com.br/?versao=011019
     agency_timezone agency_lang
1: America/Sao_Paulo          pt
2: America/Sao_Paulo          pt
```

```
gtfs$calendar
```

```
    service_id monday tuesday wednesday thursday friday saturday sunday
 1:        USD      1       1         1        1      1        1      1
 2:        U__      1       1         1        1      1        0      0
 3:        US_      1       1         1        1      1        1      0
 4:        _SD      0       0         0        0      0        1      1
 5:        __D      0       0         0        0      0        0      1
 6:        _S_      0       0         0        0      0        1      0
 7:        USD      1       1         1        1      1        1      1
 8:        U__      1       1         1        1      1        0      0
 9:        US_      1       1         1        1      1        1      0
10:        _SD      0       0         0        0      0        1      1
11:        __D      0       0         0        0      0        0      1
12:        _S_      0       0         0        0      0        1      0
    start_date   end_date
 1: 2008-01-01 2020-05-01
 2: 2008-01-01 2020-05-01
 3: 2008-01-01 2020-05-01
 4: 2008-01-01 2020-05-01
 5: 2008-01-01 2020-05-01
 6: 2008-01-01 2020-05-01
 7: 2008-01-01 2020-05-01
 8: 2008-01-01 2020-05-01
 9: 2008-01-01 2020-05-01
10: 2008-01-01 2020-05-01
11: 2008-01-01 2020-05-01
12: 2008-01-01 2020-05-01
```

O `gtfstools` disponibiliza a função `remove_duplicates()` para remover essas duplicatas. Esta função recebe como *input* um objeto GTFS e retorna o mesmo objeto, porém sem registros duplicados:

```
no_dups_gtfs <- remove_duplicates(gtfs)

no_dups_gtfs$agency
```

```
   agency_id agency_name                                agency_url
1:         1     SPTRANS http://www.sptrans.com.br/?versao=011019
     agency_timezone agency_lang
1: America/Sao_Paulo          pt
```

```
no_dups_gtfs$calendar
```

```
   service_id monday tuesday wednesday thursday friday saturday sunday
1:        USD      1       1         1        1      1        1      1
2:        U__      1       1         1        1      1        0      0
3:        US_      1       1         1        1      1        1      0
4:        _SD      0       0         0        0      0        1      1
5:        __D      0       0         0        0      0        0      1
6:        _S_      0       0         0        0      0        1      0
   start_date   end_date
1: 2008-01-01 2020-05-01
2: 2008-01-01 2020-05-01
3: 2008-01-01 2020-05-01
4: 2008-01-01 2020-05-01
5: 2008-01-01 2020-05-01
6: 2008-01-01 2020-05-01
```

Frequentemente, também, lidamos com múltiplos *feeds* em uma mesma área de estudo. Neste caso, muitas vezes gostaríamos de uni-los em um único arquivo, diminuindo assim o esforço de manipulação e processamento dos dados. Para isso, o `gtfstools` disponibiliza a função `merge_gtfs()`. O exemplo abaixo mostra o resultado da combinação de dois *feeds* distintos, o da SPTrans (sem duplicatas) e o da EMTU, de Porto Alegre:

```
poa_path <- system.file("extdata/poa_gtfs.zip", package = "gtfstools")
poa_gtfs <- read_gtfs(poa_path)

poa_gtfs$agency
```

```
   agency_id                                    agency_name             agency_url
1:      EPTC Empresa Publica de Transportes e Circulação http://www.eptc.com.br
     agency_timezone agency_lang agency_phone
1: America/Sao_Paulo          pt          156
                                                 agency_fare_url
1: http://www2.portoalegre.rs.gov.br/eptc/default.php?p_secao=155
```

```
no_dups_gtfs$agency
```

```
   agency_id agency_name                                agency_url
1:         1     SPTRANS http://www.sptrans.com.br/?versao=011019
     agency_timezone agency_lang
1: America/Sao_Paulo          pt
```

```
combined_gtfs <- merge_gtfs(no_dups_gtfs, poa_gtfs)

combined_gtfs$agency
```

```
   agency_id                                    agency_name
1:         1                                        SPTRANS
2:      EPTC Empresa Publica de Transportes e Circulação
                                agency_url   agency_timezone agency_lang
1: http://www.sptrans.com.br/?versao=011019 America/Sao_Paulo          pt
2:                   http://www.eptc.com.br America/Sao_Paulo          pt
   agency_phone                                                agency_fare_url
1:
2:          156 http://www2.portoalegre.rs.gov.br/eptc/default.php?p_secao=155
```

Como podemos ver, os registros das tabelas de ambos os *feeds* foram combinados em uma única tabela. Este é o caso quando os dois (ou mais, caso desejado) objetos GTFS possuem registros de uma mesma tabela (a *agency*, no exemplo). Caso apenas um dos objetos possua uma das tabelas, o resultado da operação de combinação copia esta tabela para o resultado final. É o caso, por exemplo, da tabela *frequencies*, que existe apenas no *feed* da SPTrans, mas não no da EMTU:

```
names(poa_gtfs)
```

```
[1] "agency"     "calendar"   "routes"     "shapes"     "stop_times"
[6] "stops"      "trips"
```

```
names(no_dups_gtfs)
```

```
[1] "agency"      "calendar"    "frequencies" "routes"      "shapes"
[6] "stop_times"  "stops"       "trips"
```

```
names(combined_gtfs)
```

```
[1] "agency"      "calendar"    "frequencies" "routes"      "shapes"
[6] "stop_times"  "stops"       "trips"
```

```
identical(no_dups_gtfs$frequencies, combined_gtfs$frequencies)
```

```
[1] TRUE
```

Um outro tipo de operação muito utilizada no tratamento de arquivos GTFS é o de filtragem desses arquivos. Frequentemente, *feeds* são usados para descrever redes de transporte público de grandíssima escala, transformando sua edição, análise e transferência em operações complexas. Por esse motivo, pesquisadores e planejadores muitas vezes precisar trabalhar com um subconjunto de dados descritos nos *feeds*. Caso desejemos estimar a acessibilidade de uma determinada região no horário de pico da manhã, por exemplo, podemos filtrar o nosso arquivo GTFS de modo a manter apenas os registros referentes a viagens que ocorrem nesse intervalo do dia.

O pacote `gtfstools` também traz diversas funções para facilitar a filtragem de arquivos GTFS. São elas:

- `filter_by_agency_id()`
- `filter_by_route_id()`
- `filter_by_service_id()`
- `filter_by_shape_id()`
- `filter_by_stop_id()`
- `filter_by_trip_id()`
- `filter_by_route_type()`
- `filter_by_weekday()`
- `filter_by_time_of_day()`
- `filter_by_sf()`

As seis primeiras (`filter_by_agency_id()`, `filter_by_route_id()`, `filter_by_service_id()`, `filter_by_shape_id()`, `filter_by_stop_id()` e `filter_by_trip_id()`) funcionam de forma muito similar. O usuário deve especificar uma vetor de identificadores, e a função mantém no objeto GTFS apenas os registros referentes a esses identificadores. O exemplo abaixo demonstra essa funcionalidade com a `filter_by_trip_id()`:

```
lobstr::obj_size(gtfs)
```

```
770.22 kB
```

```
head(gtfs$trips[, .(trip_id, trip_headsign, shape_id)])
```

```
      trip_id trip_headsign shape_id
1: CPTM L07-0       JUNDIAI    17846
2: CPTM L07-1           LUZ    17847
3: CPTM L08-0  AMADOR BUENO    17848
4: CPTM L08-1 JULIO PRESTES    17849
5: CPTM L09-0        GRAJAU    17850
6: CPTM L09-1        OSASCO    17851
```

```
smaller_gtfs <- filter_by_trip_id(gtfs, trip_id = c("CPTM L07-0", "CPTM L07-1"))

lobstr::obj_size(smaller_gtfs)
```

```
61.62 kB
```

```
head(smaller_gtfs$trips[, .(trip_id, trip_headsign, shape_id)])
```

```
      trip_id trip_headsign shape_id
1: CPTM L07-0       JUNDIAI    17846
2: CPTM L07-1           LUZ    17847
```

```
unique(smaller_gtfs$shapes$shape_id)
```

```
[1] "17846" "17847"
```

O código acima mostra que a função não filtra apenas a tabela `trips`, mas também as outras tabelas que fazem referência aos identificadores especificados. Por exemplo, a trajetória das viagens `CPTM L07-0` and `CPTM L07-1` é descrita pelos `shape_id`s `17846` and `17847`, respectivamente. Esses são, portanto, os únicos identificadores da tabela `shapes` mantidos no GTFS filtrado.

A função também funciona com o comportamento diametralmente oposto: em vez de definirmos os identificadores cujos registros devem ser *mantidos* no *feed*, especificamos os identificadores que devem ser *retirados* dele. Para isso, usamos o argumento `keep` com valor `FALSE`:

```
smaller_gtfs <- filter_by_trip_id(
  gtfs,
  c("CPTM L07-0", "CPTM L07-1"),
  keep = FALSE
)

head(smaller_gtfs$trips[, .(trip_id, trip_headsign, shape_id)])
```

```
      trip_id       trip_headsign shape_id
1: CPTM L08-0        AMADOR BUENO    17848
2: CPTM L08-1       JULIO PRESTES    17849
3: CPTM L09-0              GRAJAU    17850
4: CPTM L09-1              OSASCO    17851
5: CPTM L10-0 RIO GRANDE DA SERRA    17852
6: CPTM L10-1               BRÁS    17853
```

```
head(unique(smaller_gtfs$shapes$shape_id))
```

```
[1] "17848" "17849" "17850" "17851" "17852" "17853"
```

Como podemos ver, as viagens especificadas, bem como suas trajetórias, não estão presentes no GTFS filtrado. A mesma lógica aqui demonstrada com a `filter_by_trip_id()` é válida para as funções que filtram objetos GTFS pelos identificadores `agency_id`, `route_id`, `service_id`, `shape_id`, `stop_id` e `route_type`.

Outra operação que recorrentemente aparece em análises que envolvem dados GTFS é a de manter serviços que funcionem apenas em determinados horários do dia ou dias da semana. Para isso, o pacote disponibiliza as funções `filter_by_weekday()` e `filter_by_time_of_day()`.

A `filter_by_weekday()` recebe os dias da semana (em inglês) cujos serviços que neles operam devem ser mantidos. Adicionalmente, a função também inclui o argumento `combine`, que define como filtros de dois ou mais dias funcionam. Quando este recebe o valor `"and"`, apenas serviços

que operam em todos os dias especificados são mantidos. Quando recebe o valor `"or"`, serviços que operam em pelo menos um dos dias são mantidos:

```
smaller_gtfs <- filter_by_weekday(
  no_dups_gtfs,
  weekday = c("saturday", "sunday"),
  combine = "and"
)

smaller_gtfs$calendar[, c("service_id", "sunday", "saturday")]
```

```
   service_id sunday saturday
1:        USD      1        1
2:        _SD      1        1
```

```
smaller_gtfs <- filter_by_weekday(
  no_dups_gtfs,
  weekday = c("sunday", "saturday"),
  combine = "or"
)

smaller_gtfs$calendar[, c("service_id", "sunday", "saturday")]
```

```
   service_id sunday saturday
1:        USD      1        1
2:        US_      0        1
3:        _SD      1        1
4:        __D      1        0
5:        _S_      0        1
```

A `filter_by_time_of_day()`, por sua vez, recebe o começo e o final de uma janela de tempo e mantém os registros relacionados a viagens que rodam dentro dessa janela. O funcionamento da função depende da presença ou não da tabela `frequencies` no GTFS: o cronograma descrito na `stop_times` das viagens descritas na tabela `frequencies` não deve ser filtrado, pois, como comentado no capítulo anterior, ele serve como um modelo que dita o tempo de viagem entre uma parada e outra. Caso a `frequencies` esteja ausente, no entanto, a `stop_times` é filtrada segundo o intervalo de tempo especificado. Vamos ver como isso funciona com um exemplo:

```
smaller_gtfs <- filter_by_time_of_day(gtfs, from = "05:00:00", to = "06:00:00")
```

```r
head(smaller_gtfs$frequencies)
```

```
      trip_id start_time end_time headway_secs
1: CPTM L07-0   05:00:00 05:59:00          360
2: CPTM L07-1   05:00:00 05:59:00          360
3: CPTM L08-0   05:00:00 05:59:00          480
4: CPTM L08-1   05:00:00 05:59:00          480
5: CPTM L09-0   05:00:00 05:59:00          480
6: CPTM L09-1   05:00:00 05:59:00          480
```

```r
head(smaller_gtfs$stop_times[, c("trip_id", "departure_time", "arrival_time")])
```

```
      trip_id departure_time arrival_time
1: CPTM L07-0       04:00:00     04:00:00
2: CPTM L07-0       04:08:00     04:08:00
3: CPTM L07-0       04:16:00     04:16:00
4: CPTM L07-0       04:24:00     04:24:00
5: CPTM L07-0       04:32:00     04:32:00
6: CPTM L07-0       04:40:00     04:40:00
```

```r
frequencies <- gtfs$frequencies
gtfs$frequencies <- NULL

smaller_gtfs <- filter_by_time_of_day(gtfs, from = "05:00:00", to = "06:00:00")

head(smaller_gtfs$stop_times[, c("trip_id", "departure_time", "arrival_time")])
```

```
      trip_id departure_time arrival_time
1: CPTM L07-0       05:04:00     05:04:00
2: CPTM L07-0       05:12:00     05:12:00
3: CPTM L07-0       05:20:00     05:20:00
4: CPTM L07-0       05:28:00     05:28:00
5: CPTM L07-0       05:36:00     05:36:00
6: CPTM L07-0       05:44:00     05:44:00
```

O filtro da tabela `stop_times` pode funcionar de duas formas distintas. Uma opção é manter intactas todas as viagens que cruzam a janela de tempo especificada. A outra é manter apenas os segmentos de viagens que ocorrem dentro da janela (comportamento padrão da função). Este comportamento é controlado com o parâmetro `full_trips`, como mostrado a seguir (prestem atenção nos horários e nos segmentos presentes em cada exemplo):

```r
smaller_gtfs <- filter_by_time_of_day(
  gtfs,
  "05:00:00",
  "06:00:00",
  full_trips = TRUE
)

head(
  smaller_gtfs$stop_times[
    ,
    c("trip_id", "departure_time", "arrival_time", "stop_sequence")
  ]
)
```

```
      trip_id departure_time arrival_time stop_sequence
1: CPTM L07-0       04:00:00     04:00:00             1
2: CPTM L07-0       04:08:00     04:08:00             2
3: CPTM L07-0       04:16:00     04:16:00             3
4: CPTM L07-0       04:24:00     04:24:00             4
5: CPTM L07-0       04:32:00     04:32:00             5
6: CPTM L07-0       04:40:00     04:40:00             6
```

```r
smaller_gtfs <- filter_by_time_of_day(
  gtfs,
  "05:00:00",
  "06:00:00",
  full_trips = FALSE
)

head(
  smaller_gtfs$stop_times[
    ,
    c("trip_id", "departure_time", "arrival_time", "stop_sequence")
  ]
)
```

```
      trip_id departure_time arrival_time stop_sequence
1: CPTM L07-0       05:04:00     05:04:00             9
2: CPTM L07-0       05:12:00     05:12:00            10
3: CPTM L07-0       05:20:00     05:20:00            11
```

```
4: CPTM L07-0       05:28:00     05:28:00           12
5: CPTM L07-0       05:36:00     05:36:00           13
6: CPTM L07-0       05:44:00     05:44:00           14
```

Por fim, o pacote também disponibiliza uma função que permite filtrar o objeto GTFS usando um polígono espacial. A `filter_by_sf()` recebe um objeto do tipo `sf`/`sfc` (representação espacial estabelecida pelo pacote `sf`), ou sua *bounding box*, e mantém os registros cujas viagens são selecionadas por uma operação espacial especificada pelo usuário. Embora aparentemente complicado, este processo de filtragem é muito facilmente compreendido quando apresentado visualmente. Para isso, vamos criar uma função auxiliar:

```
library(ggplot2)

plotter <- function(gtfs,
                    geom,
                    spatial_operation = sf::st_intersects,
                    keep = TRUE,
                    do_filter = TRUE) {
  if (do_filter) {
    gtfs <- filter_by_sf(gtfs, geom, spatial_operation, keep)
  }

  shapes <- convert_shapes_to_sf(gtfs)
  trips <- get_trip_geometry(gtfs, file = "stop_times")
  geom <- sf::st_as_sfc(geom)

  ggplot() +
    geom_sf(data = trips) +
    geom_sf(data = shapes) +
    geom_sf(data = geom, fill = NA)
}
```

Esta função:

- Possui os mesmos parâmetros da `filter_by_sf()`, com a exceção do parâmetro `do_filter`, usado para mostrar os dados não filtrados;
- Condicionalmente filtra um objeto GTFS usando uma *bounding box* chamada `geom`;
- Gera a geometria das viagens usando as funções `convert_shapes_to_sf()` e `get_trip_geometry()`;
- Cria um polígono a partir da *bounding box*;

Vamos usar como exemplo a filtragem usando a *bounding box* da trajetória de *id* `68962`. O código abaixo apresenta a distribuição espacial dos dados não filtrados:

```
bbox <- sf::st_bbox(convert_shapes_to_sf(gtfs, shape_id = "68962"))

plotter(gtfs, bbox, do_filter = FALSE)
```

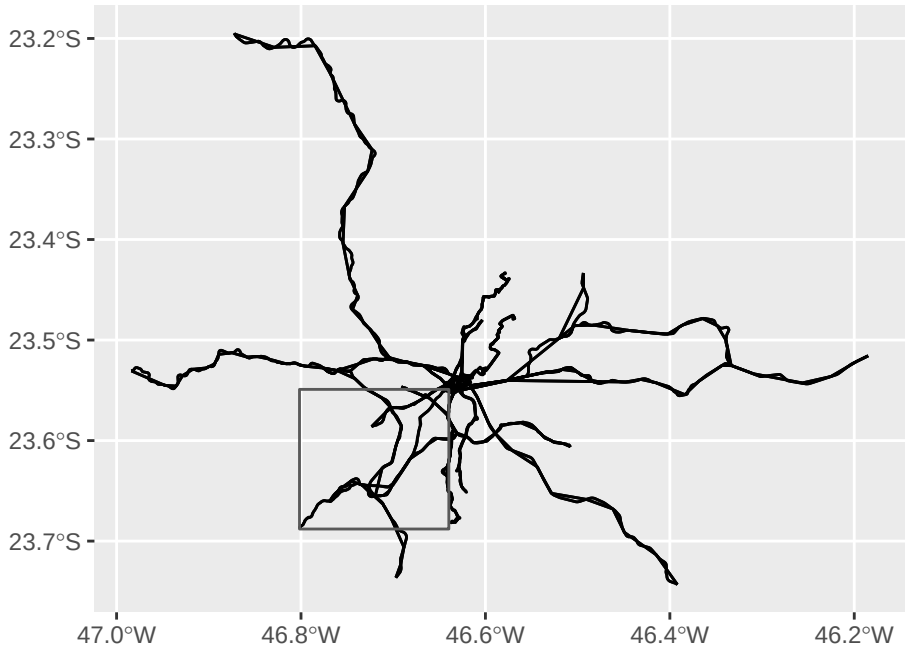

Notem aqui que nós usamos a função `convert_shapes_to_sf()`, que converte uma determinada trajetória descrita no GTFS em um objeto espacial do tipo `sf`, para obter a *bounding box* da trajetória. Por padrão, a `filter_by_sf()` (e a `plotter()`, consequentemente) mantém os dados relacionados aos registros de viagens cujas trajetórias possuem alguma interseção com o polígono espacial selecionado:

```
plotter(gtfs, bbox)
```

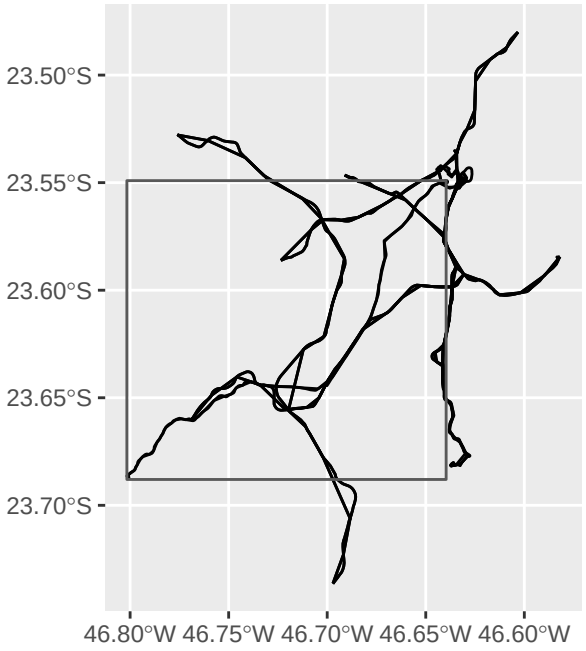

Nós podemos, no entanto, controlar a operação espacial usada no processo de filtragem. Por exemplo, o código abaixo mostra como nós podemos manter os dados relacionados a viagens que estão *contidas* dentro do polígono espacial:

```
plotter(gtfs, bbox, spatial_operation = sf::st_contains)
```

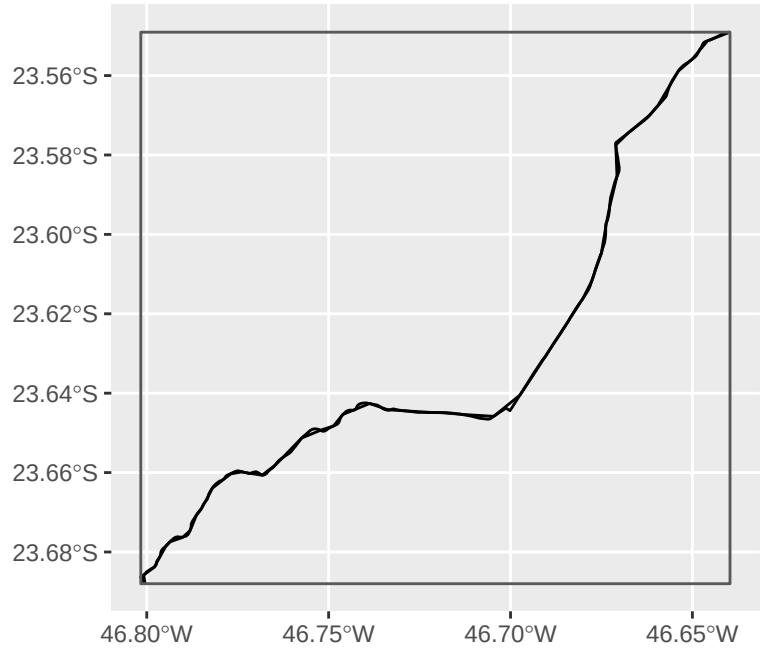

5.4 Mapeamento do *headway* das linhas

Como mostrado nas seções anteriores, o `gtfstools` disponibiliza uma grande caixa de ferramentas que podem ser usadas no processamento e na análise de arquivos GTFS. O pacote, no entanto, oferece diversas outras funções que não puderam ser apresentadas neste livro, por questões de espaço. A lista completa de funções disponíveis no pacote pode ser conferida no site do `gtfstools`.

A apresentação das funções feitas até aqui tem um importante caráter demonstrativo, porém não mostra como elas podem ser usadas de forma conjunta no desenvolvimento de uma análise de um arquivo GTFS. Esta seção preenche esta lacuna, mostrando como o pacote pode ser usado em uma análise simples, que visa responder a seguinte pergunta: como se distribuem espacialmente os tempos entre veículos de uma mesma linha (ou seja, o *headway*) no GTFS da SPTrans?

A primeira etapa é definir o escopo da nossa análise. A fim de exemplo, vamos considerar o *headway* no pico da manhã, entre 7h e 9h, em uma típica terça-feira de operação. Para isso, precisamos filtrar o nosso *feed*:

```
gtfs <- read_gtfs(path)

filtered_gtfs <- gtfs |>
```

```
  remove_duplicates() |>
  filter_by_weekday("tuesday") |>
  filter_by_time_of_day(from = "07:00:00", to = "09:00:00")

filtered_gtfs$frequencies[trip_id == "2105-10-0"]
```

```
     trip_id start_time end_time headway_secs
1: 2105-10-0   07:00:00 07:59:00          900
2: 2105-10-0   08:00:00 08:59:00         1200
```

```
filtered_gtfs$calendar
```

```
   service_id monday tuesday wednesday thursday friday saturday sunday
1:        USD      1       1         1        1      1        1      1
2:        U__      1       1         1        1      1        0      0
   start_date   end_date
1: 2008-01-01 2020-05-01
2: 2008-01-01 2020-05-01
```

Em seguida, precisamos calcular o *headway* dentro do período estabelecido. Essa informação pode ser encontrada na tabela *frequencies*, porém há um elemento complicador: cada viagem está associada a mais de um *headway, como podemos ver acima. Para resolver esta questão, portanto, vamos calcular o* headway médio* neste período.

Os primeiros registros da tabela *frequencies* do GTFS da SPTrans parecem sugerir que os períodos do dia estão listados sempre de uma em uma hora, porém isto não é uma regra estabelecida na especificação GTFS e nem é a prática adotada em outros GTFS. Por isso, nós vamos calcular a *média ponderada* do *headway* no período especificado. Para isso, nós precisamos multiplicar cada *headway* pelo intervalo de tempo em que ele é válido, e dividir o total desta soma pelo intervalo de tempo total (duas horas). Para calcular o intervalo de tempo em que cada *headway* é válido, nós usamos a função `convert_time_to_seconds()` para calcular o começo e o fim do intervalo em segundos e subtraímos o valor do fim pelo do começo, como abaixo:

```
filtered_gtfs <- convert_time_to_seconds(filtered_gtfs)

filtered_gtfs$frequencies[trip_id == "2105-10-0"]
```

```
     trip_id start_time end_time headway_secs start_time_secs end_time_secs
1: 2105-10-0   07:00:00 07:59:00          900           25200         28740
2: 2105-10-0   08:00:00 08:59:00         1200           28800         32340
```

```
filtered_gtfs$frequencies[, time_interval := end_time_secs - start_time_secs]
```

Em seguida, nós calculamos o *headway* médio:

```
avg_headway <- filtered_gtfs$frequencies[
  ,
  .(avg_headway = weighted.mean(headway_secs, w = time_interval)),
  by = trip_id
]

avg_headway[trip_id == "2105-10-0"]
```

```
    trip_id avg_headway
1: 2105-10-0        1050
```

```
head(avg_headway)
```

```
     trip_id avg_headway
1: CPTM L07-0         360
2: CPTM L07-1         360
3: CPTM L08-0         300
4: CPTM L08-1         300
5: CPTM L09-0         240
6: CPTM L09-1         240
```

Nós precisamos agora gerar a trajetória espacial de cada viagem e juntar esta informação à do *headway* médio. Para isso, nós vamos utilizar a função `get_trip_geometry()`, que, dado um objeto GTFS, retorna a trajetória espacial de suas viagens. Esta função nos permite especificar de quais viagens nós queremos as trajetórias, logo nós vamos calcular apenas as daquelas que estão presentes na tabela de *headways* médios:

```
selected_trips <- avg_headway$trip_id

geoms <- get_trip_geometry(
  filtered_gtfs,
  trip_id = selected_trips,
  file = "shapes"
)

head(geoms)
```

```
Simple feature collection with 6 features and 2 fields
Geometry type: LINESTRING
Dimension:     XY
Bounding box:  xmin: -46.98404 ymin: -23.73644 xmax: -46.63535 ymax: -23.19474
Geodetic CRS:  WGS 84
     trip_id origin_file                        geometry
1 CPTM L07-0      shapes LINESTRING (-46.63535 -23.5...
2 CPTM L07-1      shapes LINESTRING (-46.87255 -23.1...
3 CPTM L08-0      shapes LINESTRING (-46.64073 -23.5...
4 CPTM L08-1      shapes LINESTRING (-46.98404 -23.5...
5 CPTM L09-0      shapes LINESTRING (-46.77604 -23.5...
6 CPTM L09-1      shapes LINESTRING (-46.69711 -23.7...
```

O objeto `geoms` está no formato `sf`, e não no `data.table`, que precisamos que ele esteja para juntarmos à tabela de *headways*. Depois de convertê-lo para o formato desejado adequado e juntá-lo à tabela de *headways*, nós precisamos apenas configurar o nosso mapa como desejado. No exemplo abaixo, nós usamos cores e espessuras de linhas que variam de acordo com o *headway* de cada viagem:

```r
library(data.table)
library(sf)

setDT(geoms)
avg_headway[geoms, on = "trip_id", geometry := i.geometry]

ggplot(st_sf(avg_headway)) +
  geom_sf(aes(color = avg_headway, size = avg_headway))
```

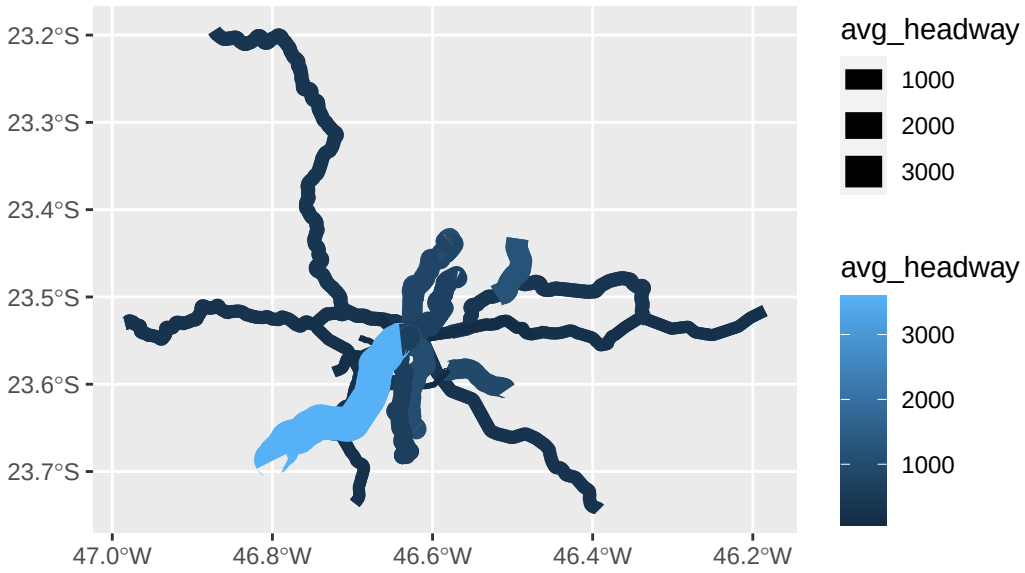

Como podemos ver, o pacote `gtfstools` torna o desenvolvimento de análises de *feeds* de transporte público algo fácil e que requer apenas o conhecimento básico de pacotes de manipulação de tabela (como o `data.table`) para grande parte das etapas que as compõem. O exemplo apresentado nesta seção mostra como muitas de suas funções podem ser usadas conjuntamente para revelar aspectos importantes de sistemas de transporte público descritos no formato GTFS.

Part IV

SEÇÃO 4: Avaliação de impacto

Objetivo: O objetivo desta seção é mostrar como avaliar o impacto de políticas urbanas sobre acessibilidade urbana usando R.

Embora muito utilizado na literatura científica, o conceito de acessibilidade ainda não é tão utilizado no planejamento e operação de sistemas de transporte público por parte de agências de transportes e tomadores de decisão. Muito disto se dá pela dificuldade de incorporar análises de acessibilidade a métodos de avaliação de projetos comumente utilizados, como análises de custo e benefício, por exemplo. Esta seção apresenta um método de avaliação de impactos de projetos e investimentos de transporte que tem na acessibilidade sua principal ferramenta.

A aplicação do método envolve a edição de arquivos GTFS, o cálculo de matrizes de custo, a tomada de decisão por trás da escolha de qual medida de acessibilidade utilizar, a estimativa dos níveis de acessibilidade, a visualização espacial desses níveis e o cálculo e análise de indicadores de desigualdade. Engloba, portanto, muitos dos pontos abordados neste livro, e serve como uma aplicação prática dos conceitos até então apresentados.

[RAFA: mencionar que uma avaliação de um projeto ou política deve ser a mais abrangente possível, considerando desde aspectos de participação social no desenho do projeto até o seu impacto em termos mais amplos considerados aspectos ambientais, econômicos, sociais, etc. A análise de impacto de acessibilidade, da qual tratamos nesse capítulo, é uma dessas dimensões de impacto.

6 Comparando a acessibilidade entre dois cenários de transporte

Neste capítulo nós avaliaremos o impacto de uma política relativamente simples, mas que pode trazer significativos benefícios em termos de acessibilidade à população: o aumento da frequência das linhas de transporte público.

Para isso, nós precisaremos comparar os níveis de acessibilidade antes e depois da suposta implementação desta política. Precisamos, portanto, modificar o GTFS original da área de estudo para atualizar as frequências das rotas nele descritas, calcular duas matrizes de tempo de viagem distintas (uma antes e outra depois da política), calcular dois conjuntos de níveis de acessibilidade distintos e comparar esse conjunto. Neste capítulo, vamos cobrir este passo-a-passo em detalhes, começando primeiro pela edição do GTFS original.

6.1 Modificação do arquivo GTFS

Nesta análise, nós usaremos novamente a amostra do GTFS da SPTrans, disponível nos pacotes `r5r` e `gtfstools`. Para simularmos um aumento na frequência das viagens de transporte público, nós precisamos diminuir o *headway* de cada viagem. Como este *feed* possui uma tabela `frequencies`, esta edição é particularmente simples: nós precisamos apenas modificar a coluna `headway_secs`. Assumindo uma diminuição de 25% no tempo entre viagens de uma mesma linha, esta manipulação se resume a apenas uma linha de código:

```
library(gtfstools)

path <- system.file("extdata/spo/spo.zip", package = "r5r")

before_gtfs <- read_gtfs(path)
after_gtfs <- read_gtfs(path)

after_gtfs$frequencies[, headway_secs := headway_secs * 0.75]

head(after_gtfs$frequencies)
```

```
      trip_id start_time end_time headway_secs
1: CPTM L07-0   04:00:00 04:59:00          540
2: CPTM L07-0   05:00:00 05:59:00          270
3: CPTM L07-0   06:00:00 06:59:00          270
4: CPTM L07-0   07:00:00 07:59:00          270
5: CPTM L07-0   08:00:00 08:59:00          270
6: CPTM L07-0   09:00:00 09:59:00          360
```

```
head(before_gtfs$frequencies)
```

```
      trip_id start_time end_time headway_secs
1: CPTM L07-0   04:00:00 04:59:00          720
2: CPTM L07-0   05:00:00 05:59:00          360
3: CPTM L07-0   06:00:00 06:59:00          360
4: CPTM L07-0   07:00:00 07:59:00          360
5: CPTM L07-0   08:00:00 08:59:00          360
6: CPTM L07-0   09:00:00 09:59:00          480
```

Pronto, isso é tudo que precisamos editar no GTFS para simular o impacto de um possível aumento na frequência das viagens de transporte público. É claro que na vida real uma proposta do tipo deve ser acompanhada de estudos de viabilidade financeira, por exemplo, para atestar sua robustez. Para fins puramente demonstrativos, no entanto, esta pequena edição já satisfaz as nossas necessidades.

6.2 Cálculo das matrizes de tempo de viagem

Tendo feito a modificação necessária no nosso GTFS, nós precisamos agora utilizá-lo para calcular a matriz de tempo de viagem, que por sua vez vamos usar para estimar os níveis de acessibilidade. Como apresentado na Section 3.1, para isso nós vamos utilizar a função `travel_time_matrix()`, do pacote `r5r`.

Antes de calcular as matrizes de fato, nós precisamos organizar os nossos arquivos na estrutura que o `r5r` requer. Cada um dos nossos cenários (antes e depois) deve ser representado por uma pasta contendo os arquivos necessários para o roteamento. Vamos criar uma pasta temporária dentro da qual vamos botar as pastas do roteamento:

```
tmpdir <- tempfile("impact_analysis")

dir.create(tmpdir)
```

```r
fs::dir_tree(tmpdir)
```

```
/tmp/RtmpapXBui/impact_analysis2f887f3959df
```

Dentro dessa pasta, vamos criar as nossas pastas de roteamento. Dentro de cada uma elas, por sua vez, vamos salvar os respectivos arquivos GTFS:

```r
before_dir <- file.path(tmpdir, "before")
after_dir <- file.path(tmpdir, "after")

dir.create(before_dir)
dir.create(after_dir)

write_gtfs(before_gtfs, path = file.path(before_dir, "before_gtfs.zip"))
write_gtfs(after_gtfs, path = file.path(after_dir, "after_gtfs.zip"))

fs::dir_tree(tmpdir)
```

```
/tmp/RtmpapXBui/impact_analysis2f887f3959df
+-- after
|   \-- after_gtfs.zip
\-- before
    \-- before_gtfs.zip
```

6.3 Cálculo da acessibilidade nos cenários antes e depois

FDSAFSAD

6.4 Visualização dos níveis e da diferença de acessibilidade

FSADFSD

6.5 Distribuição da acessibilidade entre grupos sociais

FASDFSDA

Part V

SEÇÃO: 5: Dados do Projeto AOP

Objetivo: o objetivo deste capítulo é mostrar como fazer download e analisar os dados do projeto Acesso a Oportunidades (AOP) utilizando o pacote `aopdata` no `R`.

Nos capítulos anteriores, você aprendeu como calcular indicadores de acessibilidade. No entanto, em muitos casos, você não tem disponibilidade para calcular esses indicadores por conta própria e tudo o que você quer é analisar os resultados que já foram calculados por alguém.

O projeto Acesso a Oportunidades disponibiliza uma extensa base de dados com informações sobre a distribuição da população, atividades econômicas e serviços públicos, além de várias estimativas de acessibilidade urbana para diversos tipos de atividades. Essas estimativas de acessibilidade estão disponíveis para diferentes modos de transporte (caminhada, bicicleta, transporte público e automóvel), horários do dia (pico e fora-pico), grupos populacionais (segundo níveis de renda, cor, sexo e idade) e para diferentes atividades (empregos, escolas, serviços de saúde e centros de assistência social). Nesta versão, a base de dados traz essas informações para diversos anos (2017, 2018 e 2019), se apoiando em uma única metodologia consistente para as 20 maiores cidades do Brasil. Veja abaixo **?@tbl-tabela_dados_pop** e **?@tbl-tabela_dados_access**.

> **i** As metodologias utilizadas para gerar estes dados são apresentadas em detalhe em publicações separadas, para os dados populacionais e de uso do solo (**pereira2022ususolo?**), e para os dados de acessibilidade (**pereira2022acessibilidade?**).

Part VI

Quais dados estão disponíveis?

Escopo dos dados:

Dados de população, empregos e serviços públicos:

Tabela x. Informações socioeconômicas da população e de distribuição espacial de atividades, segundo ano e fonte de dados.

Dado	Informações
Características sociodemográficas da população	Quantidade de pessoas segundo sexo, faixa de idade e cor/ra
Estabelecimentos de educação	Quantidade de creches e escolas públicas segundo nível infan
Estabelecimentos de saúde	Quantidade de estabelecimentos de saúde que atendem pelo
Atividade econômica	Quantidade de empregos formais conforme o nível de instruç
Estabelecimentos de assistência social	Quantidade de CRAS

: Informações socioeconômicas da população e de distribuição espacial de atividades, segundo ano e fonte de dados {#tbl-tabela_dados_pop}

Dados de acessibilidade urbana:

Indicador (código)	Descrição
Tempo mínimo de viagem (TMI)	Tempo até a oportunidade mais próxima
Medida cumulativa ativa (CMA)	Quantidade de oportunidades acessíveis em um determinado limite de te
Medida cumulativa passiva (CMP)	Quantidade de pessoas que acessam a localidade em um determinado limi

: Indicadores de acessibilidade calculados no Projeto Acesso a Oportunidades {#tbl-tabela_dados_access}

Todas as bases de dados criadas pelo Projeto Acesso a Oportunidades (AOP) estão disponíveis para download no site do projeto ou pelo pacote de R aopdata. Nas próximas seções são apresentados exemplos de como baixar e visualizar esses dados em `R`.

7 Dados de população e socioeconômicos

7.1 Download dos dados

Para fazer o download dos dados do projeto AOP usando o pacote aopdata, você pode usar a função `read_population()`. Essa função baixa estimativas do Censo Demográfico de 2010 do IBGE sobre a distribuição espacial da população e suas características em termos de renda domiciliar per capita, cor, sexo e idade. Nesta função, o parâmetro `city` permite você indicar os dados de qual cidade serão baixados.

Os dados estão agregados espacialmente em uma grade de hexágonos H3 na resolução 9, na qual cada hexágono tem uma área de 0.11 km2, o que equivale a aproximadamente o tamanho de um quarteirão. Para baixar os dados com as informações espaciais de geometria da grade espacial, você deve usar o parâmetro `geometry = TRUE`.

Neste exemplo, abaixo, nós mostramos como baixar os dados de população do Censo de 2010 para Fortaleza.

```
# load libraries
library(aopdata)

# download aop population data
df <- read_population(city='Fortaleza',
                      year=2010,
                      geometry = TRUE,
                      showProgress = FALSE)
```

Os dados da tabela tem essa aparência aqui:

```
head(df)
```

```
Simple feature collection with 6 features and 22 fields
Geometry type: POLYGON
Dimension:     XY
Bounding box:  xmin: -38.50828 ymin: -3.889301 xmax: -38.4983 ymax: -3.878958
Geodetic CRS:  WGS 84
```

```
  year          id_hex abbrev_muni name_muni code_muni P001 P002 P003 P004 P005
1 2010 89801040323ffff         for Fortaleza   2304400   30    8   21    0    1
2 2010 89801040327ffff         for Fortaleza   2304400  318   77  233    0    8
3 2010 8980104032bffff         for Fortaleza   2304400    0    0    0    0    0
4 2010 8980104032fffff         for Fortaleza   2304400  103   24   77    0    2
5 2010 89801040333ffff         for Fortaleza   2304400   43   11   31    0    1
6 2010 89801040337ffff         for Fortaleza   2304400  348   86  252    0   10
  P006 P007 P010 P011 P012 P013 P014 P015 P016  R001 R002 R003
1   17   13    3    4    2    3    8    9    1 168.6    1    1
2  168  150   30   50   26   38   80   82   12 202.6    1    1
3    0    0    0    0    0    0    0    0    0    NA   NA   NA
4   53   50   10   16    8   13   25   27    4 245.6    1    1
5   22   21    4    7    3    5   11   12    1 187.3    1    1
6  175  173   34   54   27   41   89   89   14 168.6    1    1
                        geometry
1 POLYGON ((-38.50232 -3.8858...
2 POLYGON ((-38.50527 -3.8840...
3 POLYGON ((-38.49932 -3.8841...
4 POLYGON ((-38.50227 -3.8824...
5 POLYGON ((-38.50237 -3.8893...
6 POLYGON ((-38.50532 -3.8875...
```

De imediato, se nota que os nomes das variáveis (colunas) da base de dados estão organizadas com códigos, como P001, P002...R001, R002 etc. A descrição completa do dicionário de variáveis está disponível aqui. A descrição de algumas dessas colunas é apresentada nas próximas seções, onde mostramos como fazer a visualização de alguns desses dados em mapas e gráficos.

7.2 Mapa de população total

Antes de visualizar os dados do `aopdata`, nós precisamos carregar algumas bibliotecas de visualização e manipulação de dados.

```
# load libraries
library(patchwork)
library(ggplot2)
library(scales)
library(sf)
```

Com um comando, é possível visualizar a distribuição espacial da população de Fortaleza. A figura mostra um mapa coroplético onde a cor de cada célula da grade espacial é preenchida com base na quantidade total de pessoas residentes (variável `P001`).

```
ggplot() +
  geom_sf(data=subset(df, P001>0), aes(fill=P001), color=NA, alpha=.8) +
  scale_fill_distiller(palette = "YlOrRd", direction = 1)+
  labs(title='Population distribution',
       subtitle = 'Fortaleza', fill="Total population") +
  theme_void()
```

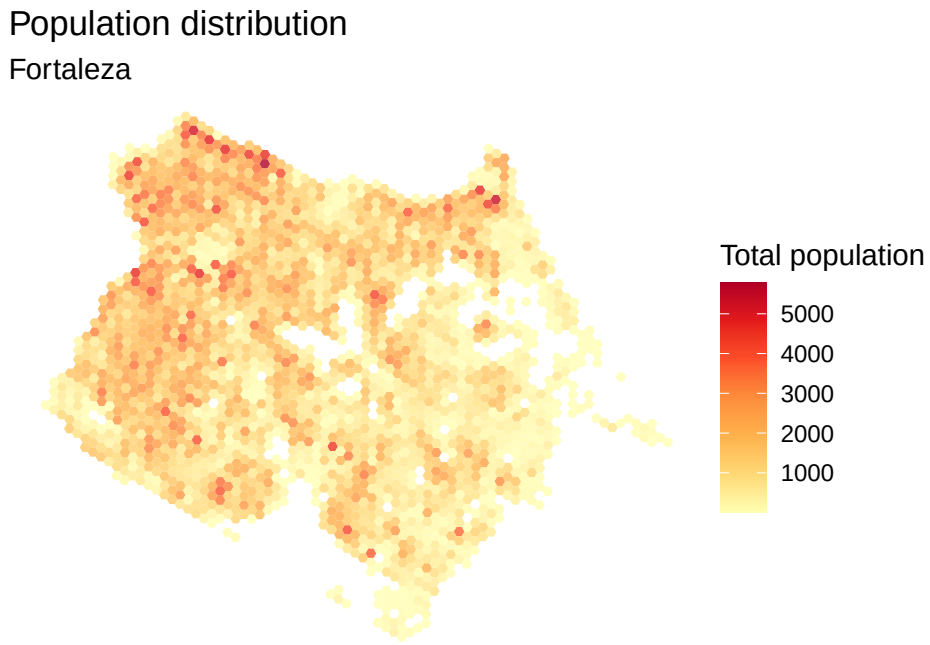

7.3 Mapa de população por cor

Além da informação sobre a população total em cada célula, o dados do `aopdata` também permitem saber a quantidade de pessoas de diferentes cores (variáveis `P002` a `P005`), sexo (variáveis `P006` e `P007`) e faixas etárias (variáveis `P010` à `P016`). O código abaixo ilustra como é simples calcular a proporção de pessoas negras e brancas em cada hexágono e visualizar esses dados num mapa.

```r
pop_b <- ggplot() +
  geom_sf(data=subset(df, P001 >0), aes(fill=P003 / P001), color=NA, alpha=.8) +
  scale_fill_distiller(palette = "RdPu", direction = 1, labels = percent, limits=c(0, 1))+
  labs(title='Proportion of black population', fill="Black pop.") +
  theme_void()

pop_w <- ggplot() +
  geom_sf(data=subset(df, P001 >0), aes(fill=P002 / P001), color=NA, alpha=.8) +
  scale_fill_distiller(palette = "YlGnBu", direction = 1, labels = percent, limits=c(0, 1)
  labs(title='Proportion of white population', fill="White pop.") +
  theme_void()

# plot figure
pop_b + pop_w
```

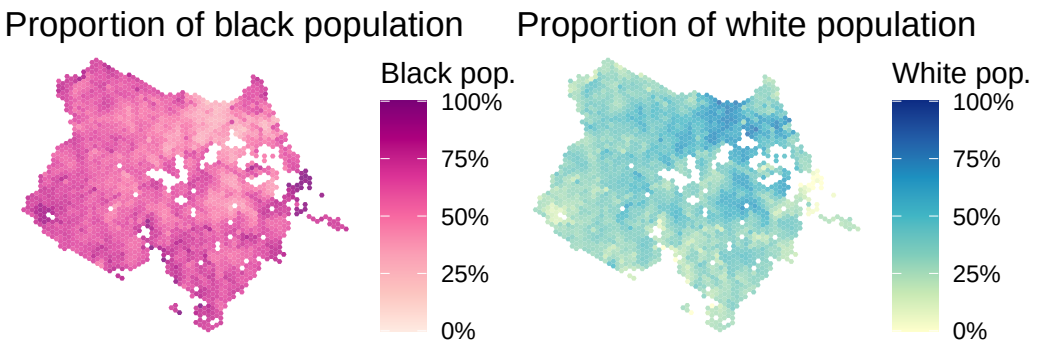

7.4 Mapa de população por renda

Os dados trazem também informação sobre a renda domiciliar per capita média de cada hexágono (R001), e sua classificação em termos de quintil (R002) e decil de renda (R003). Com esses dados, é possível visualizar com o comando abaixo a distribuição espacial dos diferentes níveis de renda da cidade.R

```
renda_c <- ggplot() +
  geom_sf(data=subset(df, P001 >0), aes(fill=R001), color=NA, alpha=.8) +
  scale_fill_distiller(palette = "YlOrRd", direction = 1)+
  labs(title='Renda domiciliar per capita média', fill="Renda em R$") +
  theme_void()

renda_d <- ggplot() +
  geom_sf(data=subset(df, !is.na(R002)), aes(fill=factor(R003)), color=NA, alpha=.8) +
  scale_fill_brewer(palette = "RdBu") +
  labs(title='Decils de renda domiciliar per capita', fill="Decil de renda") +
  theme_void() +
  theme(legend.key.size = unit(.3, 'cm'))

# plot figure
renda_c + renda_d
```

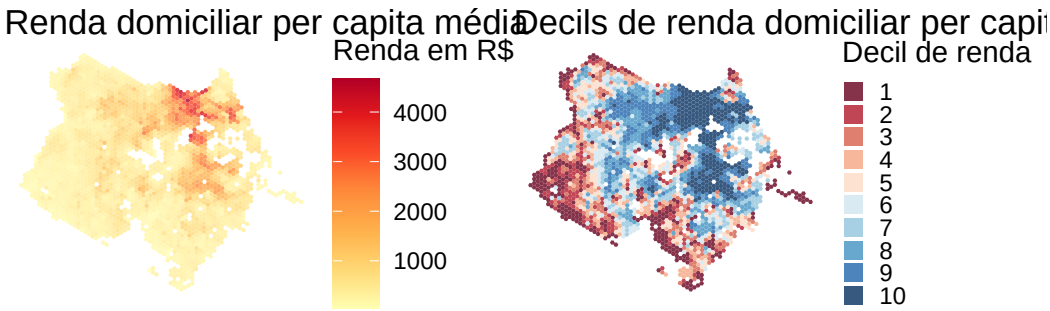

8 Dados de distribuição espacial de oportunidades

8.1 Download dos dados

O pacote `aopdata` também permite baixar, para todas cidades incluídas no projeto, dados anuais da distribuição espacial de empregos (de baixa, média e alta escolaridade), estabelecimentos de saúde (de baixa, média e alta complexidade), escolas pública (ensino infantil, fundamental e médio), e de centros de referência de assistência social (Cras).

Todos esses dados podem ser baixados com a função `read_landuse()`, que funciona da mesma maneira que a função `read_population()`. Você só precisa indicar nos parâmetros da função qual cidade (`city`) e ano (`year`) devem ser baixados, além de apontar se deseja que os dados contenham as informações espaciais dos hexágonos (`geometry = TRUE`).

Neste exemplo, abaixo, nós mostramos como baixar os dados de uso do solo no ano de 2019 para Belo Horizonte. Note que essa função automaticamente já baixa também os dados de população, automaticamente.

```
library(aopdata)

# download aop land use data
df <- read_landuse(city='Belo Horizonte',
                       year=2019,
                       geometry = TRUE,
                       showProgress = FALSE)
```

```
Downloading land use data for the year 2019
```

```
Downloading population data for the year 2010
```

```
head(df)
```

```
Simple feature collection with 6 features and 39 fields
Geometry type: POLYGON
Dimension:     XY
Bounding box:  xmin: -43.87914 ymin: -19.86084 xmax: -43.85906 ymax: -19.82421
Geodetic CRS:  WGS 84
           id_hex abbrev_muni      name_muni code_muni P001 P002 P003 P004 P005
1 89a881345a3ffff         bho Belo Horizonte   3106200    0    0    0    0    0
2 89a881345a7ffff         bho Belo Horizonte   3106200    0    0    0    0    0
3 89a881345b7ffff         bho Belo Horizonte   3106200    0    0    0    0    0
4 89a88136103ffff         bho Belo Horizonte   3106200  508  141  353    4   10
5 89a88136107ffff         bho Belo Horizonte   3106200  428  114  304    3    7
6 89a8813610bffff         bho Belo Horizonte   3106200  399  111  277    3    8
  P006 P007 P010 P011 P012 P013 P014 P015 P016  R001 R002 R003 year T001 T002
1    0    0    0    0    0    0    0    0    0    NA   NA   NA 2019    0    0
2    0    0    0    0    0    0    0    0    0    NA   NA   NA 2019    0    0
3    0    0    0    0    0    0    0    0    0    NA   NA   NA 2019    0    0
4  253  255   53   86   30   43  176  110   10 502.9    2    3 2019  100   17
5  210  218   42   72   27   38  142   98    9 491.8    2    3 2019   44   19
6  203  196   42   68   24   34  138   86    7 502.8    2    3 2019  104   31
  T003 T004 E001 E002 E003 E004 M001 M002 M003 M004 S001 S002 S003 S004 C001
1    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
2    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
3    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
4   72   11    1    1    0    0  321  321    0    0    0    0    0    0    0
5   23    2    0    0    0    0    0    0    0    0    0    0    0    0    0
6   58   15    1    0    1    0  817    0  817    0    0    0    0    0    0
                       geometry
1 POLYGON ((-43.86011 -19.829...
2 POLYGON ((-43.86313 -19.827...
3 POLYGON ((-43.86321 -19.830...
4 POLYGON ((-43.8731 -19.8608...
5 POLYGON ((-43.87612 -19.859...
6 POLYGON ((-43.87001 -19.859...
```

Antes de visualizar os dados de uso do solo nas próxima seções, vamos carregar algumas bibliotecas de visualização e manipulação de dados.

```
# load libraries
library(patchwork)
library(ggplot2)
library(scales)
library(sf)
```

8.2 Mapa de empregos

Como nos exemplos anteriores, é possível visualizar o mapa de distribuição espacial de empregos usando o pacote `ggplot2` com o código abaixo:

```
ggplot() +
  geom_sf(data=df, aes(fill=T001), color=NA, alpha=.9) +
  scale_fill_distiller(palette = "YlGnBu", direction = 1) +
  labs(title='Distribuição espacial de empregos',
       subtitle = 'Belo Horizonte', fill="N. de empregos") +
  theme_void()
```

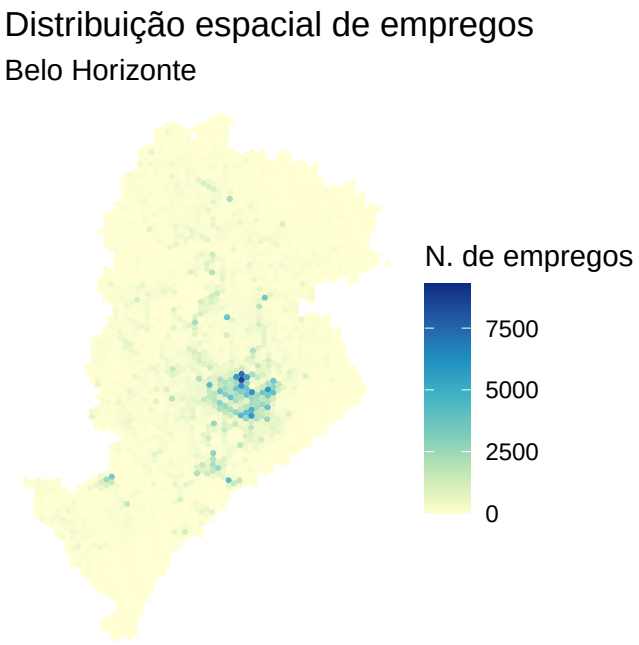

8.3 Mapa de escolas

As variáveis que indicam o número de escolas em cada célula são aquelas que começam com a letra `E__`. Neste exemplo abaixo, nós mapeamos a distribuição espacial de todas escolas de Belo Horizonte a partir da variável `E001`.

```
ggplot() +
  geom_sf(data=df, aes(fill=as.factor(E001)), color=NA, alpha=.9) +
```

```
 scale_fill_brewer(palette = "YlGnBu", direction = 1) +
labs(title='Distribuição espacial de escolas',
     subtitle = 'Belo Horizonte', fill="N. de escolas") +
theme_void()
```

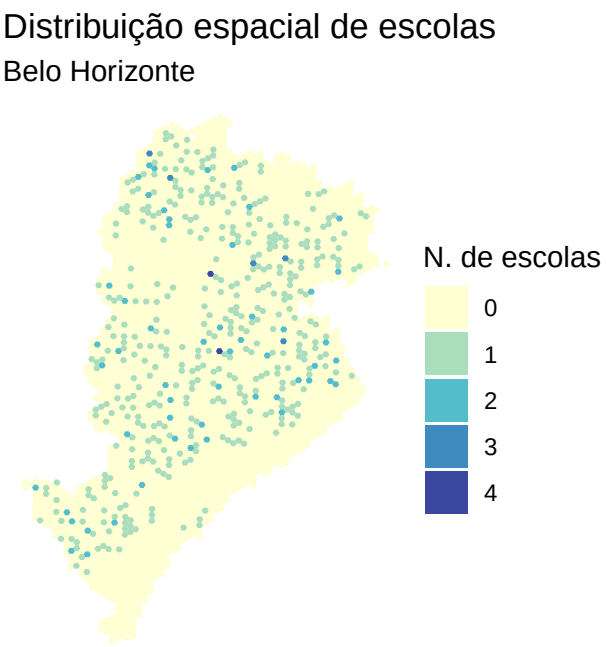

8.4 Mapa de estabelecimentos de saúde

Para analisar a distribuição espacial de estabelecimentos de saúde, você deve analisar as variáveis que começam com a letra `S___`. O código abaixo nos permite comparar a distribuição espacial de estabelecimentos de saúde de baixa complexidade (`S002`) e alta complexidade (`S004`).

```
sau_b <- ggplot() +
          geom_sf(data=df, aes(fill=as.factor(S002)), color=NA, alpha=.9) +
          scale_fill_brewer(palette = "YlGnBu", direction = 1, limits=factor(0:4)) +
          labs(title='Estabelecimentos de saúde', subtitle = 'Baixa complexidade',
               fill="N. de estabelecimentos") +
          theme_void()

sau_a <- ggplot() +
```

```
          geom_sf(data=df, aes(fill=as.factor(S004)), color=NA, alpha=.9) +
          scale_fill_brewer(palette = "YlGnBu", direction = 1, limits=factor(0:4)) +
          labs(title='Estabelecimentos de saúde', subtitle = 'Alta complexidade',
               fill="N. de estabelecimentos") +
          theme_void()

# plot maps
sau_b  + sau_a  + plot_layout(guides = 'collect')
```

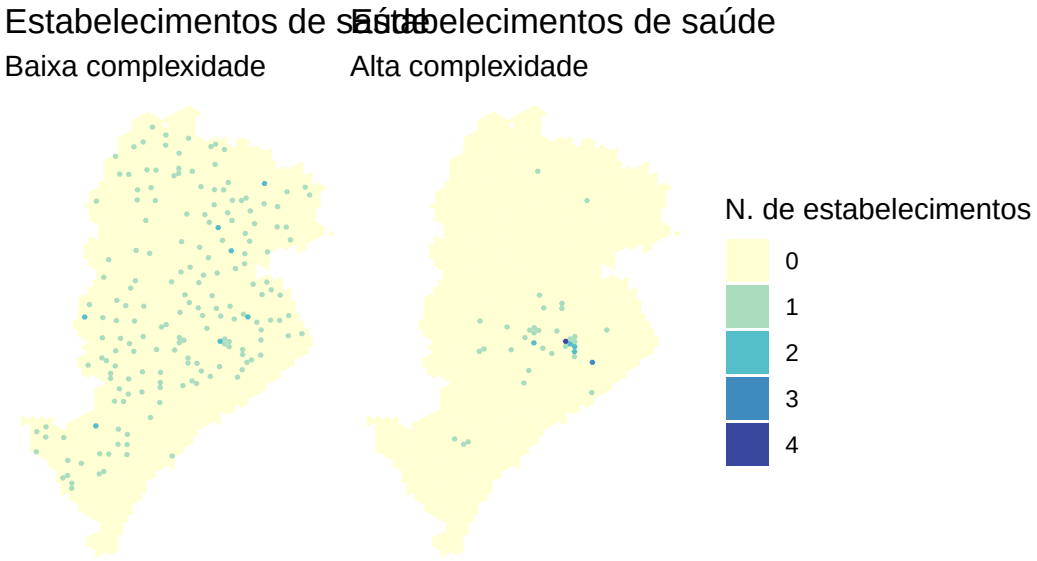

8.5 Mapa de CRAS

Por fim, a distribuição espacial dos Centros de Referência de Assistência Social (Cras) pode ser analisada com a variável `C001`.

```
ggplot() +
  geom_sf(data=df, aes(fill=as.factor(C001)), color=NA, alpha=.9) +
   scale_fill_brewer(palette = "YlGnBu", direction = 1) +
  labs(title='Centros de Referência de Assistência Social (Cras)',
       subtitle = 'Belo Horizonte', fill="N. de Cras") +
  theme_void()
```

Centros de Referência de Assistência Social (Cras)

Belo Horizonte

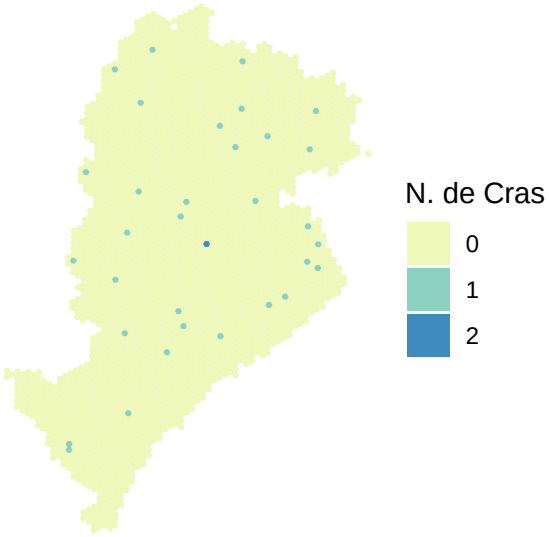

9 Estimativas e mapas de acessibilidade

9.1 Download dos dados

Finalmente, o pacote `aopdata` também permite baixar, para todas cidades incluídas no projeto, estimativas anuais de acesso a empregos, serviços saúde, educação e assistência social por modo de transporte

Todos esses dados podem ser baixados com a função `read_access()`, que funciona da mesma maneira que as funções `read_population()` e `read_landuse()` apresentadas nos capítulos anteriores. Aqui, no entanto, além de indicar a cidade (`city`) e o ano (`year`) de referência para baixar os dados, você também precisa informar qual o modo de transporte (`mode`) será baixado e se você quer estimativas de acessibilidade no horário de pico (`peak = TRUE`) ou fora-pico (`peak = TRUE`). Esses dados representam a acessibilidade mediana do período de pico (entre 6h e 8h) e fora-pico (entre 14h e 16h).

Neste exemplo, abaixo, nós mostramos como baixar os dados de uso de acessibilidade urbana no ano de 2019 para São Paulo no período de pico. Nesse exemplo, nós baixamos tanto as estimativas de acessibilidade por automóvel quanto por transporte público, e empilhamos os dados num único `data.frame`. Note que essa função automaticamente já baixa também os dados de população e de uso do solo, automaticamente.

```
library(aopdata)

# download aop accessibility data
df_pt <- read_access(
  city='São Paulo',
  mode='public_transport',
  year=2019,
  peak = TRUE,
  geometry = TRUE,
  showProgress = FALSE
)

df_car <- read_access(
  city='São Paulo',
```

```
  mode='car',
  year=2019,
  peak = TRUE,
  geometry = TRUE,
  showProgress = FALSE
)

# row bind into a single data.frame
df <- rbind(df_pt, df_car)
head(df)
```

```
Simple feature collection with 6 features and 205 fields
Geometry type: POLYGON
Dimension:     XY
Bounding box:  xmin: -46.63863 ymin: -23.71413 xmax: -46.62834 ymax: -23.70485
Geodetic CRS:  WGS 84
           id_hex abbrev_muni name_muni code_muni year P001 P002 P003 P004 P005
1 89a81000003ffff         spo Sao Paulo   3550308 2019  322  127  190    0    5
2 89a81000007ffff         spo Sao Paulo   3550308 2019   16    3   13    0    0
3 89a8100000bffff         spo Sao Paulo   3550308 2019 2386 1142 1232    2   10
4 89a8100000fffff         spo Sao Paulo   3550308 2019  885  260  622    0    3
5 89a81000013ffff         spo Sao Paulo   3550308 2019  725  340  380    0    5
6 89a81000017ffff         spo Sao Paulo   3550308 2019  211  110   98    0    3
  P006 P007 P010 P011 P012 P013 P014 P015 P016  R001 R002 R003 T001 T002 T003
1  158  164   33   63   28   35   85   75    3 477.6    2    3   72   19   50
2    9    7    2    2    2    3    2    5    0  65.7    1    1    0    0    0
3 1216 1170  247  410  174  269  682  572   32 377.2    1    1   52    6   24
4  460  425   96  124   88  127  175  266    9 363.9    1    1    0    0    0
5  371  354   85  129   51   78  196  173   13 503.5    2    3    0    0    0
6  104  107   20   33   16   25   52   59    6 687.9    3    6  113   18   65
  T004 E001 E002 E003 E004 M001 M002 M003 M004 S001 S002 S003 S004 C001
1    3    0    0    0    0    0    0    0    0    0    0    0    0
2    0    0    0    0    0    0    0    0    0    0    0    0    0
3   22    0    0    0    0    0    0    0    0    0    0    0    0
4    0    0    0    0    0    0    0    0    0    0    0    0    0
5    0    0    0    0    0    0    0    0    0    0    0    0    0
6   30    2    0    2    1 1477    0 1168  309    0    0    0    0
              mode peak CMATT15 CMATB15 CMATM15 CMATA15 CMAST15 CMASB15 CMASM15
1 public_transport    1     315      71     175      69       0       0       0
2 public_transport    1     313      70     174      69       0       0       0
3 public_transport    1     229      43     161      25       2       2       2
4 public_transport    1     551     123     343      85       3       3       3
```

```
5 public_transport    1     421      90     262      69       2       2       2
6 public_transport    1     312      76     187      49       0       0       0
  CMASA15 CMAET15 CMAEI15 CMAEF15 CMAEM15 CMAMT15 CMAMI15 CMAMF15 CMAMM15
1       0       2       0       2       1    1477       0    1168     309
2       0       2       0       2       1    1477       0    1168     309
3       0       0       0       0       0       0       0       0       0
4       0       4       1       3       2    3132     460    1965     707
5       0       2       0       2       1    1477       0    1168     309
6       0       2       0       2       1    1477       0    1168     309
  CMACT15 CMPPT15 CMPPH15 CMPPM15 CMPPB15 CMPPA15 CMPPI15 CMPPN15 CMPP0005I15
1       0    4895    2428    2467    2238      27       2    2628         505
2       0    4895    2428    2467    2238      27       2    2628         505
3       0    9537    4645    4892    4685      64       3    4785         872
4       0   13109    6331    6778    6453      61       8    6587        1088
5       0    4934    2452    2482    2368      48       0    2518         461
6       0    3199    1608    1591    1567      20       0    1612         317
  CMPP0614I15 CMPP1518I15 CMPP1924I15 CMPP2539I15 CMPP4069I15 CMPP70I15 CMATT30
1         809         371         566        1313        1247        84    4797
2         809         371         566        1313        1247        84    4228
3        1538         726        1138        2550        2539       174    2648
4        2012         967        1575        3383        3783       301    6200
5         749         373         587        1271        1372       121    5773
6         487         239         374         807         891        84    6608
  CMATB30 CMATM30 CMATA30 CMAST30 CMASB30 CMASM30 CMASA30 CMAET30 CMAEI30
1    1293    2789     715       5       5       5       0      18       5
2    1170    2452     606       4       4       4       0      13       4
3     714    1526     408       4       4       4       0       9       2
4    1598    3641     961       5       5       5       0      19       6
5    1589    3271     913       5       5       5       0      18       5
6    1821    3659    1128       6       6       6       0      22       5
  CMAEF30 CMAEM30 CMAMT30 CMAMI30 CMAMF30 CMAMM30 CMACT30 CMPPT30 CMPPH30
1      13       4   15148    2409   10765    1974       1   59041   28457
2       9       3   10497    1949    6931    1617       1   40049   19392
3       7       3    7222    1069    5137    1016       1   59792   28974
4      13       5   15710    2527   10551    2632       2  101380   48709
5      13       4   15148    2409   10765    1974       1   81985   39473
6      17       5   19547    2409   14343    2795       1   83186   40111
  CMPPM30 CMPPB30 CMPPA30 CMPPI30 CMPPN30 CMPP0005I30 CMPP0614I30 CMPP1518I30
1   30584   28535     446      29   30031        5263        8809        4111
2   20657   19159     273      14   20603        3610        6061        2866
3   30818   28424     365      25   30978        5376        9204        4241
4   52671   47601     955      66   52758        9076       15239        6971
5   42512   39784     695      49   41457        7189       12278        5675
```

```
6   43075   40359     728      51   42048        7302       12371        5749
  CMPP1924I30 CMPP2539I30 CMPP4069I30 CMPP70I30 CMATT60 CMATB60 CMATM60 CMATA60
1        6817       15664       16733      1644   96195   18711   54773   22711
2        4673       10486       11274      1079   72810   14161   40949   17700
3        6927       15859       16646      1539  147237   26399   82208   38630
4       11658       27259       28303      2874  107938   21292   61768   24878
5        9311       21712       23351      2469  161353   28971   91687   40695
6        9459       22070       23710      2525  158016   28997   91280   37739
  CMAST60 CMASB60 CMASM60 CMASA60 CMAET60 CMAEI60 CMAEF60 CMAEM60 CMAMT60
1      50      38      48       6     120      40      76      29   87761
2      40      34      39       2     108      36      68      28   79902
3      57      45      56       5     135      45      88      30   93958
4      56      43      54       6     128      42      82      31   92799
5      59      44      57       7     141      47      90      32   97925
6      56      43      54       6     139      47      87      32   96281
  CMAMI60 CMAMF60 CMAMM60 CMACT60 CMPPT60 CMPPH60 CMPPM60 CMPPB60 CMPPA60
1   15059   56558   16144       5  547471  259971  287500  277734   11134
2   14014   50455   15433       5  501558  238550  263008  247962    8781
3   16318   61918   15722       6  633994  299454  334540  339064   19838
4   15615   60049   17135       5  689942  325560  364382  378571   21810
5   16744   63838   17343       6  666492  314759  351733  360532   20661
6   16812   62265   17204       6  632529  299225  333304  334655   17957
  CMPPI60 CMPPN60 CMPP0005I60 CMPP0614I60 CMPP1518I60 CMPP1924I60 CMPP2539I60
1     407  258196        44866        76195        34899        59393       146870
2     383  244432        41903        71199        32501        54873       134759
3     473  274619        49586        83666        38585        67298       169669
4     496  289065        53223        89680        41446        72354       184045
5     483  284816        51720        87430        40333        70418       178015
6     451  279466        49804        84545        38888        67458       168928
  CMPP4069I60 CMPP70I60 CMATT90 CMATB90 CMATM90 CMATA90 CMAST90 CMASB90 CMASM90
1      162048     23200 1168463  166686  577124  424653     169     111     160
2      146361     19962 1088120  153982  540566  393572     160     107     152
3      194234     30956 1428750  211239  719220  498291     190     119     179
4      214049     35145 1362473  191461  669950  501062     182     117     172
5      205504     33072 1443193  211449  723001  508743     203     131     191
6      192822     30084 1406215  203383  701014  501818     204     132     193
  CMASA90 CMAET90 CMAEI90 CMAEF90 CMAEM90 CMAMT90 CMAMI90 CMAMF90 CMAMM90
1      42     337     107     207      92  218542   30864  131526   56152
2      39     328     105     201      90  213963   30365  128917   54681
3      50     370     123     222     101  232126   34693  138061   59372
4      46     355     117     214      92  223492   32779  134438   56275
5      51     415     136     248     114  264729   38719  158252   67758
6      51     415     137     247     114  266946   39578  159137   68231
```

```
  CMACT90 CMPPT90 CMPPH90 CMPPM90 CMPPB90 CMPPA90 CMPPI90 CMPPN90 CMPP0005I90
1      10 1697502  790958  906544 1113577   80011    1336  502578      111963
2       9 1617428  753988  863440 1054271   74800    1240  487117      107419
3      10 1918445  894649 1023796 1274988   90290    1602  551565      125137
4      10 2096063  978494 1117569 1384576   94542    2065  614880      138110
5      12 2027043  946208 1080835 1333715   91633    1714  599981      133501
6      12 1950319  910888 1039431 1272271   88334    1558  588156      129637
  CMPP0614I90 CMPP1518I90 CMPP1924I90 CMPP2539I90 CMPP4069I90 CMPP70I90
1      183412       87698      165449      454122      573567    121291
2      176240       84154      157827      432825      545306    113657
3      204140       97829      187004      513061      650643    140631
4      225800      107835      205069      561408      707435    150406
5      218843      104726      198411      541774      684520    145268
6      212862      101535      191408      521731      655761    137385
  CMATT120 CMATB120 CMATM120 CMATA120 CMAST120 CMASB120 CMASM120 CMASA120
1  2136716   328724  1094450   713542       357       235       338        82
2  2095040   321900  1068319   704821       355       235       337        80
3  2203072   344047  1136019   723006       374       243       356        86
4  2494268   397258  1308021   788989       418       266       395        97
5  2275396   357833  1177979   739584       401       265       381        90
6  2195795   342423  1130056   723316       387       257       367        88
  CMAET120 CMAEI120 CMAEF120 CMAEM120 CMAMT120 CMAMI120 CMAMF120 CMAMM120
1      821       288       481       221    518042     83000    313683    121359
2      815       288       479       216    516846     83610    313657    119579
3      855       293       508       230    532772     82410    323147    127215
4      976       340       576       260    610890     97742    369803    143345
5      948       333       559       251    600516     97066    367244    136206
6      942       334       554       254    604830     98765    368433    137632
  CMACT120 CMPPT120 CMPPH120 CMPPM120 CMPPB120 CMPPA120 CMPPI120 CMPPN120
1       20  4018897  1890513  2128384  2540395   134426     4039  1340037
2       20  3860887  1814742  2046145  2445536   130803     3868  1280680
3       21  4320562  2032079  2288483  2745882   142238     4320  1428122
4       24  4752649  2234731  2517918  3037441   153875     5098  1556235
5       22  4351102  2049261  2301841  2735091   140022     4377  1471612
6       21  4191716  1974700  2217016  2627575   136196     4172  1423773
  CMPP0005I120 CMPP0614I120 CMPP1518I120 CMPP1924I120 CMPP2539I120 CMPP4069I120
1       281477       467671       217602       408477      1084792      1300130
2       269676       448086       208699       391944      1041317      1251187
3       301337       501274       233530       439651      1163931      1400822
4       330744       549438       256378       484187      1277780      1541189
5       307070       511736       237911       444278      1173140      1401287
6       297029       494835       229726       427661      1129908      1348228
  CMPP70I120 TMIST TMISB TMISM TMISA TMIET TMIEI TMIEF TMIEM TMICT
```

```
1     258748    17    17    17    53   8.0    26   8.0   8.0    21
2     249978    21    21    21    55   9.0    28   9.0   9.0    23
3     280017    13    13    13    50  17.0    26  17.0  17.0    30
4     312933    13    13    13    53   7.0    13   7.0   7.0    28
5     275680    12    12    12    51   8.0    24   8.0   8.0    19
6     264329    16    16    16    49   5.8    22   5.8   5.8    16
                        geometry
1 POLYGON ((-46.63251 -23.711...
2 POLYGON ((-46.63552 -23.709...
3 POLYGON ((-46.62941 -23.709...
4 POLYGON ((-46.63242 -23.708...
5 POLYGON ((-46.6326 -23.7141...
6 POLYGON ((-46.63561 -23.712...
```

Os nomes das variáveis (colunas) com estimativas de acessibilidade também estão organizadas com códigos, como `CMAEF30`, `TMISB` ou `CMPPM60`. O nome das colunas com estimativas de acessibilidade são a junção de três componentes: 1) Tipo de indicador de acessibilidade 2) Tipo de oportunidade / pessoas 3) Tempo limite

1) O **tipo de indicador** de acessibilidade é indicado pelas primeiras 3 letras. O projeto AOP atualmente inclui três tipos de indicadores:

- `CMA` Indicador de acessibilidade cumulativo ativo
- `CMP` Indicador de acessibilidade cumulativo passivo

- `TMI` Indicador de tempo mínimo até oportunidade mais próxima

2) O **tipo de atividade** é indicado pelas letras seguintes, no meio do nome da variável. O projeto AOP atualmente inclui diversos tipos de atividades:

- `TT` Todos empregos
- `TB` Empregos de baixa escolaridade
- `TM` Empregos de média escolaridade
- `TA` Empregos de alta escolaridade
- `ST` Todos estabelecimentos de saúde
- `SB` Estabelecimentos de saúde de baixa complexidade
- `SM` Estabelecimentos de saúde de média complexidade
- `SA` Estabelecimentos de saúde de alta complexidade
- … e assim por diante.

No caso do indicador de acessibilidade passiva (`CMP`), as letras do meio do nome da variável indicam qual o grupo populacional de referência.

- `PT` População total

- `PH` População de homens
- `PM` População de mulheres
- `PB` População branca
- `PN` População negra
- `P1924I` População de 19 a 24 anos de idade
- `P2539I` População de 25 a 39 anos de idade

3) O **tempo limite de viagem** é indicado pelos números no final do nome da variável. Esses números somente se aplicam para os indicadores de acessibildade cumulativa ativa (`CMA`) e passiva (`CMP`).

Exemplos:

CMAEF30: Número de escolas de ensino fundamental acessíveis em até 30 minutos

TMISB: Tempo de viagem até o estabelecimento de saúde mais próximo com serviços de baixa complexidade

CMPPM60: Quantidade de mulheres que conseguem acessar determinado hexágono em até 60 minutos

Lembre-se, a descrição completa do dicionário de variáveis está disponível no site to pacote aopdata.

A seguir, nós mostramos alguns exemplos de como visualizar essas estimativas de acessibilidade.

9.2 Mapa do tempo para acessar o hospital mais próximo

Neste exemplo, nós vamos comparar o nível de acessibilidade até hospitais entre modos automóvel *vs* transporte público. Para analisar qual o tempo mínimo de viagem (`TMI`) até um hospital de alta complexidade (`SA`), nós precisamos analisar a variável `TMISA`. Com o código abaixo, nós carregamos as bibliotecas para manipulação e visualização de dados, e visualizamos a distribuição espacial dos valores de `TMISA` para ambos modos de transporte.

Note, no entanto, que os tempos de viagem por transporte público costumam ser muito mais longos do que por automóvel. Então para facilitar a visualização dos resultados, nós truncamos a distribuição dos valores de `TMISA` em 60 minutos ou mais.

```
# load libraries
library(ggplot2)
library(data.table)
library(patchwork)
library(scales)
```

```
library(sf)


# truncate max values to 60 min.
df$TMISA <- ifelse(df$TMISA > 60, 60, df$TMISA)

# plot
ggplot() +
  geom_sf(data=subset(df, !is.na(mode)), aes(fill=TMISA), color=NA, alpha=.9) +
  scale_fill_viridis_c(option = 'cividis', direction = -1,
                       breaks = seq(0,60,10),
                       labels = c(seq(0,50,10), "60+")) +
  labs(title='Tempo de viagem até hospital de alta complex. mais próximo',
       subtitle = 'São Paulo', fill="Tempo em\nminutos") +
  facet_grid(.~mode) +
  theme_void()
```

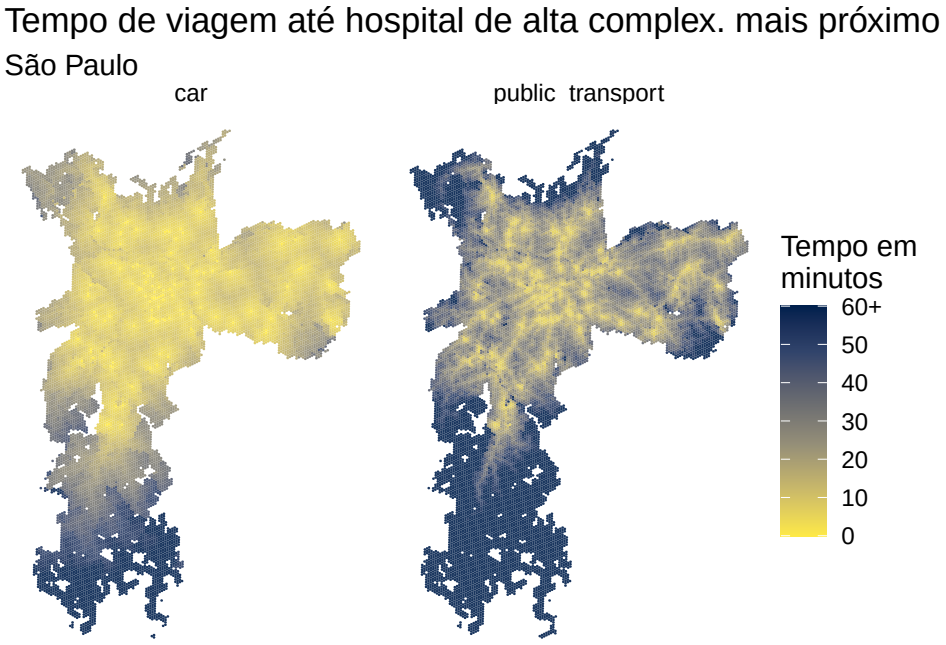

9.3 Mapa da quantidade de oportunidades acessíveis

Uma vez que os dados já foram baixados do `aopdata`, é muito simples comparar por exemplo a quantidade de oportunidades acessíveis em diferentes tempos de viagem. O código abaixo

ilustra como visualizar num mapa o número de empregos acessíveis em até 60 e 90 minutos de viagem por transporte público, e como colocar esses mapas lado a lado para comparação.

```
# limits for legend scale
value_limits <- c(0, max(df_pt$CMATT90, na.rm=T)/1000)

# create maps
fig60 <- ggplot() +
          geom_sf(data=subset(df_pt, !is.na(mode)), aes(fill=CMATT60/1000), color=NA, alph
          scale_fill_viridis_c(option = 'inferno', limits = value_limits) +
          labs(subtitle = 'em até 60 min.', fill="Empregos") +
          theme_void()

fig90 <- ggplot() +
          geom_sf(data=subset(df_pt, !is.na(mode)), aes(fill=CMATT90/1000), color=NA, alph
          scale_fill_viridis_c(option = 'inferno', limits = value_limits) +
          labs(subtitle = 'em até 90 min.', fill="Empregos") +
          theme_void()

# plot figure
fig60 + fig90 +
  plot_layout(guides = 'collect') +
  plot_annotation(title = 'Quantidade de empregos acessíveis por transporte público',
                  subtitle = "São Paulo")
```

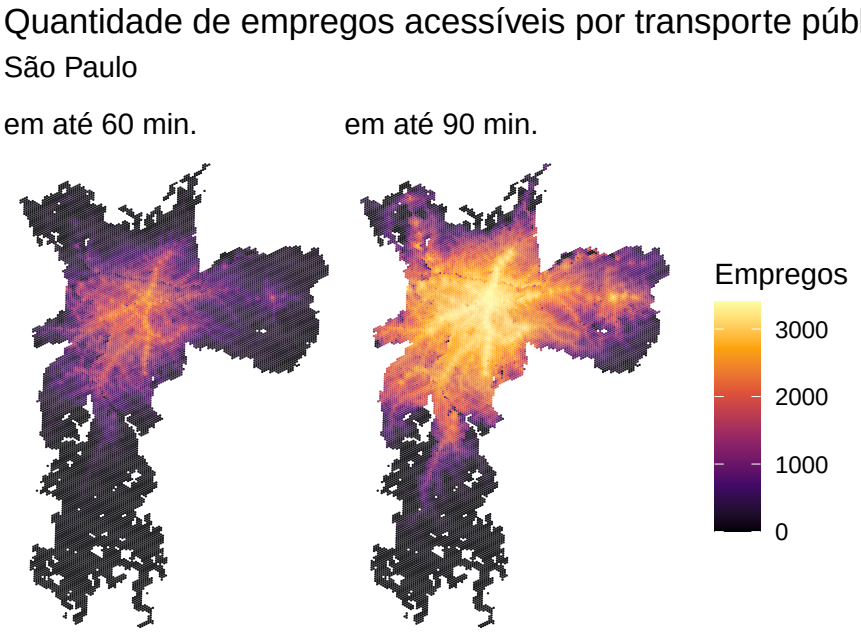

9.4 Desigualdades de acesso a oportunidades

Existem diversas maneiras de se analisar quão desiguais são as condições de acesso a oportunidades a partir dos dados do `aopdata`. Nós apresentamos nesta subseção três exemplos de como esse tipo de análise pode ser realizada.

Desigualdade no tempo de acesso `TMI`

Neste primeiro exemplo, nós vamos comparar qual o tempo médio de viagem até o hospital mais próximo para pessoas de diferentes níveis de renda. Para isso, o código abaixo calcula o valor médio de `TMISA` ponderada pela população em cada hexágono. Essa ponderação é necessária porque o número de hexágonos pode variar muito entre hexágonos.

Antes disso, cabe observar que alguns hexágonos da cidade não conseguem acessar nenhum hospital em até 2h de viagem. Em casos como esse, o valor das variáveis `TMI__` é infinito (`Inf`). Para lidar com esses casos, nós substituímos abaixo todos valores `Inf` por 120 minutos.

```
# copy data to new data.table
dt <- copy(df_pt)
setDT(dt)

# replace Inf travel time with 120
```

```r
dt[, TMISA := fifelse(TMISA==Inf, 120, TMISA)]

# calculate average travel time by income
temp <- dt[, .(average = weighted.mean(x=TMISA, w=P001, na.rm=T)), by=R003]
temp <- na.omit(temp)

ggplot() +
  geom_col(data=temp, aes(y=average, x=factor(R003)), fill='#2c9e9e', color=NA) +
  scale_x_discrete(labels=c("D1\n+Pobres", paste0('D', 2:9), "D10\n+Ricos")) +
  labs(title = 'Média de tempo de viagem até o hospital mais proximo',
       subtitle = 'por transporte público em São Paulo',
       x='Decil de renda', y='Tempo de viagem\nem min.') +
  theme_minimal()
```

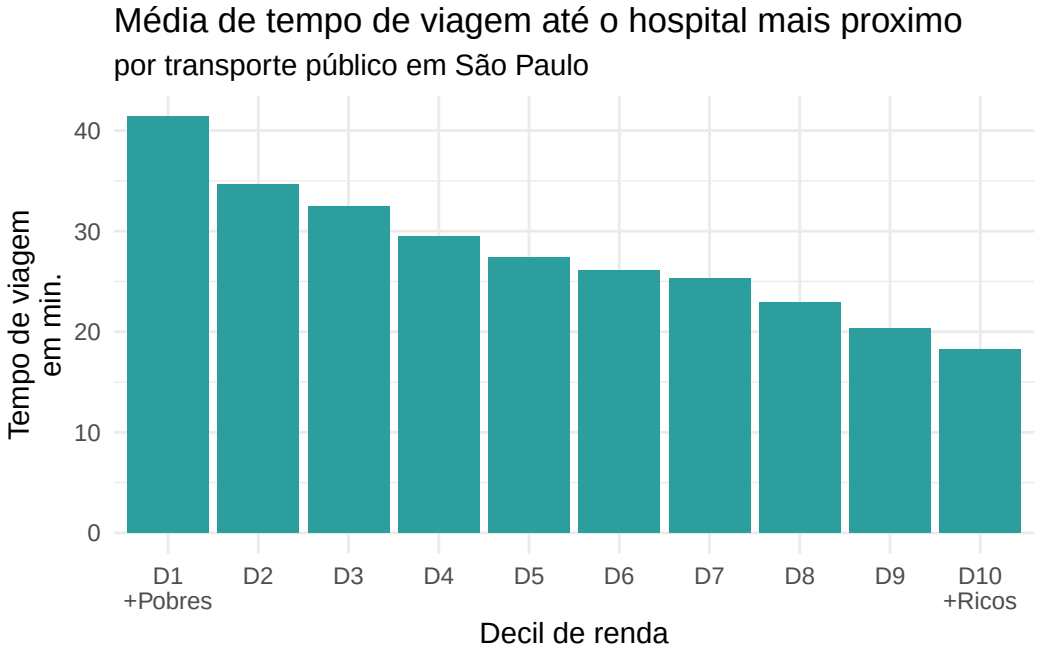

Desigualdade do número de oportunidades acessíveis `CMA`

Outra maneira de examinar a desigualdade de acesso a oportunidades é comparar a quantidade de oportunidades acessíveis por diferentes grupos populacionais considerando-se um mesmo modo de transporte e tempo de viagem. Nesse caso, nós analisamos o Indicador de acessibilidade cumulativo ativo (`CMA`).

Neste exemplo abaixo, nós utilizamos *box plots* para comparar a quantidade de empregos acessíveis por transporte público em até 30 minutos de viagem.

```
ggplot() +
  geom_boxplot(data=subset(dt, !is.na(R003)),
               aes(x = factor(R003), y=CMATT60/1000, color=factor(R003))) +
  scale_color_brewer(palette = 'RdBu') +
  labs(title='Distribução do número de empregos acessíveis em até 30 min.', color="Decil\n
       subtitle='por transporte público, São Paulo',
       x='Decil de renda', y="N. de empregos acessíveis\n(em milhares)") +
  scale_x_discrete(labels=c("D1\n+Pobres", paste0('D', 2:9), "D10\n+Ricos")) +
  theme_minimal()
```

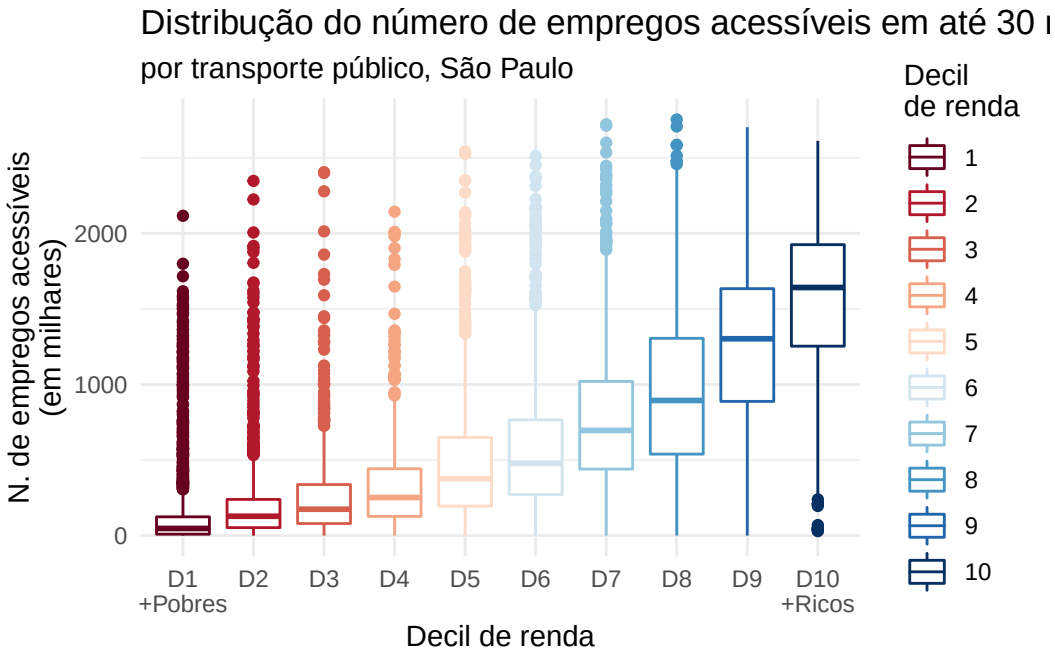

Também é possível comparar como diferentes modos de transporte possibilitam diferentes níveis de acessibilidade, e como essa diferença pode variar muito entre cidades. Nesse exemplo, abaixo, nós vamos comparar a quantidade de empregos acessíveis em até 30 minutos de viagem a pé e de carro. O primeiro passo é baixar os dados de acessibilidade a pé e por automóvel para todas as cidades.

```
# download data
df_car <- read_access(city = 'all', mode='car', year = 2019, showProgress = FALSE)
df_walk <- read_access(city = 'all', mode='walk', year = 2019, showProgress = FALSE)
```

O próximo passo é calcular para cada cidade a média ponderada do número de empregos acessíveis em até 30 minutos (`CMATT30`) para cada um dos modos de transporte. Com esses

resultados prontos para cada modo, nós juntamos essas estimativas num único `data.frame` e calculamos a razão da acessibilidade por carro dividida pela acessibilidade à pé.

```
# calculate the average number of jobs accessible in 30min
df_car2 <- df_car[, .(access_car = weighted.mean(CMATT30, w = P001, na.rm=T)), by=name_mun
df_walk2 <- df_walk[, .(access_walk = weighted.mean(CMATT30, w = P001, na.rm=T)), by=name_

# merge and get the ratio between walking and driving access
df <- merge(df_car2, df_walk2)
df[, ratio := access_car/access_walk]

head(df)
```

```
       name_muni access_car access_walk    ratio
1:          Belem   155270.4    9392.235 16.53179
2: Belo Horizonte   529890.0   12464.233 42.51284
3:       Brasilia   220575.9    4110.703 53.65892
4:       Campinas   256333.1    6748.923 37.98133
5:   Campo Grande   172680.5    4181.209 41.29919
6:       Curitiba   494376.9   10471.135 47.21331
```

Pronto, agora é só visualizar os resultados. Como esperado, a figura abaixo mostra que é possível acessar muito mais empregos em 30 min. por automóvel do que em caminhada. No entanto, essa diferença varia muito entre cidades. Em São Paulo e em Brasília, 30 minutos de viagem por automóvel permite acessar, em média, um número de empregos 54 vezes maior do que a pé. Em Belém, onde observamos a menor diferença, o automóvel ainda permite acessar 17 vezes mais empregos do que a caminhada.

```
# plot
ggplot(data=df, aes(x=ratio, y=reorder(name_muni, ratio))) +
  geom_bar(stat='identity') +
  geom_text(aes(x=ratio+6 , label=paste0(round(ratio),'x'))) +
  labs(title = 'Diferença da quantidade de empregos acessiveis por\nautomóvel vs a pé',
       subtitle= 'em até 30 min. de viagem',
       y='', x='Número de vezes') +
  theme_classic()
```

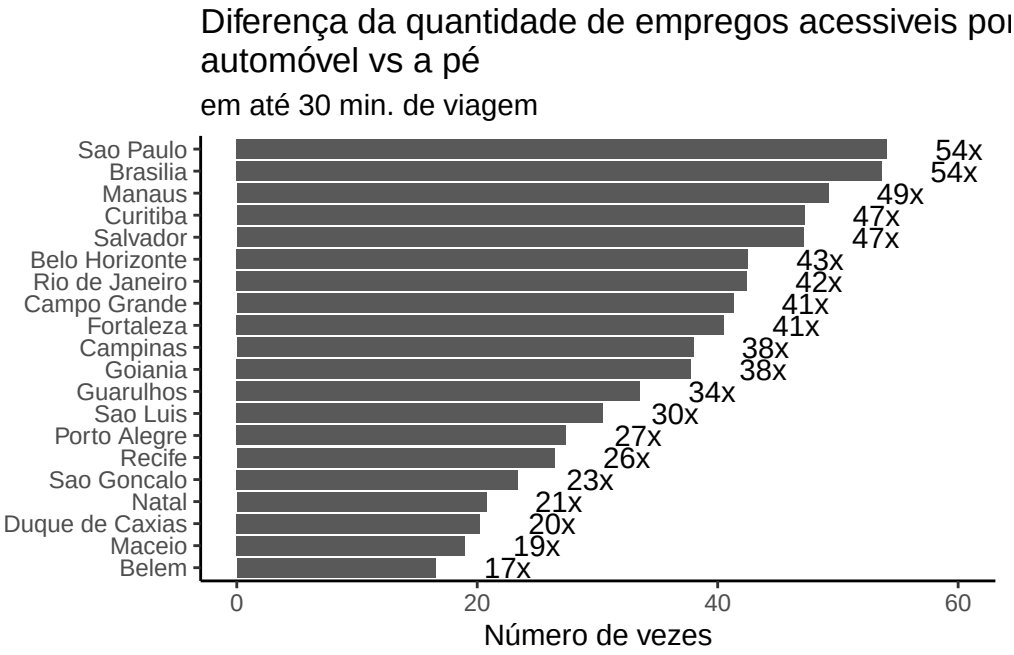
Diferença da quantidade de empregos acessiveis por
automóvel vs a pé
em até 30 min. de viagem
Sao Paulo
Brasilia
Manaus
Curitiba
Salvador
Belo Horizonte
Rio de Janeiro
Campo Grande
Fortaleza
Campinas
Goiania
Guarulhos
Sao Luis
Porto Alegre
Recife
Sao Goncalo
Natal
Duque de Caxias
Maceio
Belem
54x
54x
49x
47x
47x
43x
42x
41x
41x
38x
38x
34x
30x
27x
26x
23x
21x
20x
19x
17x
0
20
40
60
Número de vezes

Referências bibliográficas

Arbex, Renato, and Claudio B. Cunha. 2020. "Estimating the Influence of Crowding and Travel Time Variability on Accessibility to Jobs in a Large Public Transport Network Using Smart Card Big Data." *Journal of Transport Geography* 85 (May): 102671. https://doi.org/10.1016/j.jtrangeo.2020.102671.

Banister, David. 2011. "The Trilogy of Distance, Speed and Time." *Journal of Transport Geography* 19 (4): 950–59. https://doi.org/10.1016/j.jtrangeo.2010.12.004.

Bertolini, L., F. le Clercq, and L. Kapoen. 2005. "Sustainable Accessibility: A Conceptual Framework to Integrate Transport and Land Use Plan-Making. Two Test-Applications in the Netherlands and a Reflection on the Way Forward." *Transport Policy* 12 (3): 207–20. https://doi.org/10.1016/j.tranpol.2005.01.006.

Brodsky, Isaac. 2018. "H3: Uber's Hexagonal Hierarchical Spatial Index." *Uber Engineering Blog*. https://eng.uber.com/h3/.

Church, A, M Frost, and K Sullivan. 2000. "Transport and Social Exclusion in London." *Transport Policy* 7 (3): 195–205. https://doi.org/10.1016/S0967-070X(00)00024-X.

Conway, Matthew Wigginton, Andrew Byrd, and Marco van der Linden. 2017. "Evidence-Based Transit and Land Use Sketch Planning Using Interactive Accessibility Methods on Combined Schedule and Headway-Based Networks." *Transportation Research Record: Journal of the Transportation Research Board* 2653 (1): 45–53. https://doi.org/10.3141/2653-06.

Dijst, Martin, Tom de Jong, and Jan Ritsema van Eck. 2002. "Opportunities for Transport Mode Change: An Exploration of a Disaggregated Approach." *Environment and Planning B: Planning and Design* 29 (3): 413–30. https://doi.org/10.1068/b12811.

Dong, Xiaojing, Moshe E. Ben-Akiva, John L. Bowman, and Joan L. Walker. 2006. "Moving from Trip-Based to Activity-Based Measures of Accessibility." *Transportation Research Part A: Policy and Practice* 40 (2): 163–80. https://doi.org/10.1016/j.tra.2005.05.002.

El-Geneidy, Ahmed, David Levinson, Ehab Diab, Genevieve Boisjoly, David Verbich, and Charis Loong. 2016. "The Cost of Equity: Assessing Transit Accessibility and Social Disparity Using Total Travel Cost." *Transportation Research Part A: Policy and Practice* 91 (September): 302–16. https://doi.org/10.1016/j.tra.2016.07.003.

Farrington, John, and Conor Farrington. 2005. "Rural Accessibility, Social Inclusion and Social Justice: Towards Conceptualisation." *Journal of Transport Geography* 13 (1): 1–12. https://doi.org/10.1016/j.jtrangeo.2004.10.002.

Geurs, Karst, and Bert van Wee. 2004. "Accessibility Evaluation of Land-Use and Transport Strategies: Review and Research Directions." *Journal of Transport Geography* 12 (2): 127–40. https://doi.org/10.1016/j.jtrangeo.2003.10.005.

Herszenhut, Daniel, Rafael H. M. Pereira, Licinio da Silva Portugal, and Matheus Henrique de Sousa Oliveira. 2022. "The Impact of Transit Monetary Costs on Transport Inequality." *Journal of Transport Geography* 99 (February): 103309. https://doi.org/10.1016/j.jtrangeo.2022.103309.

Higgins, Christopher, Matthew Palm, Amber DeJohn, Luna Xi, James Vaughan, Steven Farber, Michael Widener, and Eric Miller. 2022. "Calculating Place-Based Transit Accessibility: Methods, Tools and Algorithmic Dependence." *Journal of Transport and Land Use* 15 (1). https://doi.org/10.5198/jtlu.2022.2012.

Levinson, David, and David King. 2020. *Transport Access Manual: A Guide for Measuring Connection Between People and Places*. Committee of the Transport Access Manual, University of Sydney.

Lucas, Karen, Giulio Mattioli, Ersilia Verlinghieri, and Alvaro Guzman. 2016. "Transport Poverty and Its Adverse Social Consequences." *Proceedings of the Institution of Civil Engineers - Transport* 169 (6): 353–65. https://doi.org/10.1680/jtran.15.00073.

Luo, Wei, and Fahui Wang. 2003. "Measures of Spatial Accessibility to Health Care in a GIS Environment: Synthesis and a Case Study in the Chicago Region." *Environment and Planning B: Planning and Design* 30 (6): 865–84. https://doi.org/10.1068/b29120.

Miller, Eric J. 2018. "Accessibility: Measurement and Application in Transportation Planning." *Transport Reviews* 38 (5): 551–55. https://doi.org/10.1080/01441647.2018.1492778.

Neutens, Tijs, Matthias Delafontaine, Darren M. Scott, and Philippe De Maeyer. 2012. "An Analysis of Day-to-Day Variations in Individual Space–time Accessibility." *Journal of Transport Geography*, Special Issue on Time Geography, 23 (July): 81–91. https://doi.org/10.1016/j.jtrangeo.2012.04.001.

Neutens, Tijs, Tim Schwanen, Frank Witlox, and Philippe De Maeyer. 2010. "Equity of Urban Service Delivery: A Comparison of Different Accessibility Measures." *Environment and Planning A: Economy and Space* 42 (7): 1613–35. https://doi.org/10.1068/a4230.

Paez, Antonio, Christopher D. Higgins, and Salvatore F. Vivona. 2019. "Demand and Level of Service Inflation in Floating Catchment Area (FCA) Methods." Edited by Tayyab Ikram Shah. *PLOS ONE* 14 (6): e0218773. https://doi.org/10.1371/journal.pone.0218773.

Páez, Antonio, Darren M. Scott, and Catherine Morency. 2012. "Measuring Accessibility: Positive and Normative Implementations of Various Accessibility Indicators." *Journal of Transport Geography* 25 (November): 141–53. https://doi.org/10.1016/j.jtrangeo.2012.03.016.

Papa, Enrica, Cecilia Silva, Marco Te Brömmelstroet, and Angela Hull. 2015. "Accessibility Instruments for Planning Practice: A Review of European Experiences." *Journal of Transport and Land Use*, June. https://doi.org/10.5198/jtlu.2015.585.

Pereira, Rafael H. M., Marcus Saraiva, Daniel Herszenhut, Carlos Kaue Vieira Braga, and Matthew Wigginton Conway. 2021. "R5r: Rapid Realistic Routing on Multimodal Transport Networks with R^5 in R." *Transport Findings*, March, 21262. https://doi.org/10.32866/001c.21262.

Pereira, Rafael H. M., Tim Schwanen, and David Banister. 2017. "Distributive Justice and Equity in Transportation." *Transport Reviews* 37 (2): 170–91. https://doi.org/10.1080/01441647.2016.1257660.

Venter, Christoffel. 2016. "Assessing the Potential of Bus Rapid Transit-Led Network Restructuring for Enhancing Affordable Access to Employment – The Case of Johannesburg's Corridors of Freedom." *Research in Transportation Economics* 59 (November): 441–49. https://doi.org/10.1016/j.retrec.2016.05.006.